

Семинар по выбору

1. Использование похожести (similarity) в распределенной оптимизации.

Докладчик: Дмитрий Былинкин.

Современные оптимизационные задачи требуют всё больших вычислительных мощностей, которые невозможно обеспечить на одном устройстве. Распределенные постановки, где вычисления делятся между несколькими машинами, становятся неотъемлемой частью оптимизации. Обмен данными между устройствами, необходимый для синхронизации вычислений, зачастую становится узким местом, ограничивающим производительность большинства распределенных алгоритмов. Один из способов сокращения коммуникационных затрат — использование похожести локальных данных. Доклад представляет собой беглый обзор последних результатов в этой области. В частности, речь пойдет о:

- Явлении концентрации меры — теоретическом фундаменте похожести данных;
- Оптимальном методе в смысле раундов коммуникации;
- Редукции дисперсии в условиях похожести данных — рассмотрим оптимальный метод в смысле количества коммуникаций;
- Актуальных направлениях исследований вокруг похожести.

Дата: -

2. Методы римановой оптимизации на многообразиях матриц и тензоров.

Докладчик: Александр Моложавенко.

Риманова оптимизация — стремительно развивающаяся область численных методов оптимизации, заключающаяся в минимизации функционалов, определенных на гладких многообразиях. На семинаре разберемся с понятием риманова многообразия, встроенного в конечномерное нормированное пространство. Пронаблюдаем конкретные примеры. Познакомимся с основными ингредиентами построения алгоритмов римановой оптимизации: проекция на касательное пространство, ретракция и вектор транспорт. Выясним явный вид этих элементов на примере многообразия матриц с ортонормированными столбцами (многообразия Штифеля) и многообразия матриц фиксированного ранга, с обобщением на тензорный случай.

Дата: -

3. Применение теории оптимизации для задачи переноса домена.

Докладчик: Никита Корнилов.

В задаче переноса домена нужно преобразовать изображения из одного домена в другой, при этом сохранив близость входа и выхода. То есть минимизировать норму разности между входом и выходом по преобразованиям, переносящим домены. Например, можно научиться делать из котов максимально похожих песиков, или из фото человека его аниме версию.

Однако загвоздка в том, что мы не знаем нужных пар вход-выход и гарантировать, что преобразование перенесет домены тоже не получается. Тут на помощь приходит теория двойственных задач, которая позволяет переформулировать ограничения и

всё-таки построить вычислимые алгоритмы. На семинаре мы посмотрим, как вывести эти методы в теории и реализовать на практике.

Дата: -

4. Защита от атак на нейронные сети с помощью пробной функции и доверительных весов.

Докладчик: Глеб Молодцов и Даня Медяков.

Распределённое обучение — это важная компонента обучения современного ИИ, но его децентрализованная природа является и его уязвимым местом. Представьте, что каждый участник процесса должен прийти к консенсусу, не доверяя никому, ведь среди них могут быть злоумышленники, намеренно вносящие дезинформацию. Это и есть Византийская атака, способная незаметно разрушить всю совместную работу. Мы представляем метод, который действует как детектор для нейронных сетей: с помощью пробной функции мы проверяем отправленные с каждого клиента обновления, а на основе доверительных весов формируем итоговое решение. Ключевой результат — наша система не просто устойчива к наличию Византийцев, она продолжает эффективно обучаться, даже когда атакующие составляют большинство. Более того, наш подход универсален и интегрируется в реальные сценарии с оптимизаторами вроде Adam и локальным обучением, обеспечивая жизнеспособность распределённого ИИ в условиях недоверия. Мы посмотрим на работу представленного подхода в различных практических сетапах: от классификаций/регрессий на публичных данных до работы с приватными данными ЭКГ из реальных медицинских учреждений. При этом мы разберем, как добиться асимптотически оптимальных теоретических оценок сходимости.

Дата: -

5. Методы оптимизации круглых тензоров

Докладчик: Андрей Веприков и Солодкин Владимир.

В докладе рассматриваются современные методы оптимизации, явно учитывающие матричную структуру параметров нейронных сетей. Несмотря на то, что в большинстве архитектур параметры имеют вид матриц (двумерных тензоров), классические алгоритмы оптимизации, такие как SGD, sign-SGD и AdamW, действуют покомпонентно и фактически игнорируют эту структуру.

В первой части доклада обсуждается постановка метода наискорейшего спуска (steepest descent) в матричном случае. Показано, что выбор нормы во входном пространстве параметров определяет вид шага оптимизации: так, для векторных параметров использование евклидовой нормы приводит к классическому SGD, а бесконечной нормы — к sign-SGD. При переходе к матричным параметрам возникает широкий класс естественных матричных норм и индуцированных ими метрик, что позволяет строить на первый взгляд различные, но в существенном смысле близкие алгоритмы оптимизации. Обсуждаются возникающие при этом связи между геометрией пространства параметров и свойствами алгоритмов.

Во второй части доклада рассматриваются квази-ньютоновские методы в матричной форме. Поскольку параметры модели имеют размерность матриц, встает вопрос о том, как согласованно и эффективно приближать матрицу Гессеана. Анализируются

подходы, в которых аппроксимация Гессiana осуществляется в виде произведения или композиции двух матриц более низкой сложности, и показывается, как соответствующие конструкции естественным образом связаны с матричными нормами и геометрией, обсуждаемыми в первой части.

Дата: -

6. Стохастический градиентный спуск как стохастический процесс: базовые принципы и новые идеи

Докладчик: Игнашин Игорь.

Стохастический градиентный спуск — один из фундаментальных методов обучения нейронных сетей. Его обычно воспринимают как простой алгоритм обновления весов по мини-батчам, однако за этим стоит более глубокий взгляд: SGD можно рассматривать как дискретный стохастический процесс, эволюционирующий во времени. На семинаре мы разберём базовую формальную запись SGD и увидим, как из неё возникает представление об обучении как о динамической системе. Поймём, откуда появляется «шум» — почему выбор мини-батча приводит к случайным колебаниям параметров, и как этот шум зависит от шага обучения и структуры задачи.

Обсудим популярную интуицию, что SGD похож на броуновское движение с гауссовским шумом, и разберём, какие аргументы стоят за этим приближением. Покажем, как в некоторых работах пытаются аппроксимировать шум SGD нормальным распределением — например, поворачивая пространство параметров в удобный базис.

Затем мы посмотрим, почему эта картина оказывается неполной. На простых примерах увидим, что реальный шум SGD ведёт себя иначе, чем гауссовский: зависит от направления, от кривизны ландшафта и даже от величины шага обучения. В практической части сравним искусственно зашумлённые траектории с реальными траекториями SGD и увидим ключевые различия.

Дата: -

7. Natural Gradient Descent. Оптимизация на пространстве распределений

Докладчик: Шестаков Александр

Обычный градиентный спуск можно рассматривать как «наискорейший» спуск в ℓ_2 норме. Однако такой подход никак учитывает внутреннюю структуру задачи, например, распределения исходных данных. На семинаре мы разберем вероятностные постановки задачи, как записать «наискорейший» спуск с метрикой Фишера. Рассмотрим, чем отличаются истинная/эмпирическая матрица Фишера и Гаусс-Ньютоновское приближение. Выведем явные формулы для модельных задач — регрессии и классификации, увидим связь с методом Ньютона. В конце поговорим о вычислительных приближениях, используемых в глубоком обучении и обучении с подкреплением.

Дата: -

8. Обобщенная гладкость: определение, сложности исследования, механизмы для анализов

Докладчик: Сава Чежегов

Как правило, методы оптимизации стараются построить теорию сходимости популярных алгоритмов. Одним из ключевых аспектов таких исследований является

класс исследуемых функций, который задаётся некими предположениями. На вашем курсе в течение лекционного цикла было рассказано множество алгоритмов и анализов их сходимостей, в которых предполагалась так называемая L -гладкость. К сожалению, класс функций с таким предположением довольно ограничен, а что самое главное — оно не всегда выполнено на практике (например, при использовании нейронных сетей). Естественным расширением класса исследуемых функций является так называемая (L_0, L_1) — гладкость (или обобщенная гладкость). На данном семинаре мы поговорим о данном предположении, насколько оно выполнено в реальности, и познакомимся с техниками, позволяющими строить анализы сходимости для уже известных нам методов оптимизации для данного предположения.

Дата: -