

Семинар по выбору

1. Защита от атак на нейронные сети с помощью пробной функции и доверительных весов.

Докладчик: Глеб Молодцов и Даня Медяков.

Распределённое обучение — это важная компонента обучения современного ИИ, но его децентрализованная природа является и его уязвимом местом. Представьте, что каждый участник процесса должен прийти к консенсусу, не доверяя никому, ведь среди них могут быть злоумышленники, намеренно вносящие дезинформацию. Это и есть Византийская атака, способная незаметно разрушить всю совместную работу. Мы представляем метод, который действует как детектор для нейронных сетей: с помощью пробной функции мы проверяем отправленные с каждого клиента обновления, а на основе доверительных весов формируем итоговое решение. Ключевой результат — наша система не просто устойчива к наличию Византийцев, она продолжает эффективно обучаться, даже когда атакующие составляют большинство. Более того, наш подход универсален и интегрируется в реальные сценарии с оптимизаторами вроде Adam и локальным обучением, обеспечивая жизнеспособность распределённого ИИ в условиях недоверия. Мы посмотрим на работу представленного подхода в различных практических сетапах: от классификаций/регрессий на публичных данных до работы с приватными данными ЭКГ из реальных медицинских учреждений. При этом мы разберем, как добиться асимптотически оптимальных теоретических оценок сходимости.

Дата: 1 декабря 17:05.

2. Natural Gradient Descent. Оптимизация на пространстве распределений.

Докладчик: Саша Шестаков.

Обычный градиентный спуск можно рассматривать как «наискорейший» спуск в ℓ_2 норме. Однако такой подход никак учитывает внутреннюю структуру задачи, например, распределения исходных данных. На семинаре мы разберем вероятностные постановки задачи, как записать «наискорейший» спуск с метрикой Фишера. Рассмотрим, чем отличаются истинная/эмпирическая матрица Фишера и Гаусс-Ньютоновское приближение. Выведем явные формулы для модельных задач — регрессии и классификации, увидим связь с методом Ньютона. В конце поговорим о вычислительных приближениях, используемых в глубоком обучении и обучении с подкреплением.

Дата: 3 декабря 17:05.

3. Обобщенная гладкость: определение, сложности исследования, механизмы для анализов.

Докладчик: Сава Чежегов.

Как правило, методы оптимизации стараются построить теорию сходимости популярных алгоритмов. Одним из ключевых аспектов таких исследований является класс исследуемых функций, который задаётся некими предположениями. На вашем курсе в течение лекционного цикла было рассказано множество алгоритмов и анализов их сходимостей, в которых предполагалась так называемая L-гладкость. К сожалению, класс функций с таким предположением довольно ограничен, а что

самое главное — оно не всегда выполнено на практике (например, при использовании нейронных сетей). Естественным расширением класса исследуемых функций является так называемая (L_0, L_1) — гладкость (или обобщенная гладкость). На данном семинаре мы поговорим о данном предположении, насколько оно выполнено в реальности, и познакомимся с техниками, позволяющими строить анализ сходимости для уже известных нам методов оптимизации для данного предположения.

Дата: 4 декабря 12:20.

4. Методы римановой оптимизации на многообразиях матриц и тензоров.

Докладчик: Саша Моложавенко.

Риманова оптимизация — стремительно развивающаяся область численных методов оптимизации, заключающаяся в минимизации функционалов, определенных на гладких многообразиях. На семинаре разберемся с понятием риманова многообразия, встроенного в конечномерное нормированное пространство. Пронаблюдаем конкретные примеры. Познакомимся с основными ингредиентами построения алгоритмов римановой оптимизации: проекция на касательное пространство, ретракция и вектор транспорт. Выясним явный вид этих элементов на примере многообразия матриц с ортонормированными столбцами (многообразия Штифеля) и многообразия матриц фиксированного ранга, с обобщением на тензорный случай.

Дата: 4 декабря 13:55.

5. Использование похожести (similarity) в распределенной оптимизации.

Докладчик: Дима Былинкин.

Современные оптимизационные задачи требуют всё больших вычислительных мощностей, которые невозможно обеспечить на одном устройстве. Распределенные постановки, где вычисления делятся между несколькими машинами, становятся неотъемлемой частью оптимизации. Обмен данными между устройствами, необходимый для синхронизации вычислений, зачастую становится узким местом, ограничивающим производительность большинства распределенных алгоритмов. Один из способов сокращения коммуникационных затрат — использование похожести локальных данных. Доклад представляет собой беглый обзор последних результатов в этой области. В частности, речь пойдет о:

- Явлении концентрации меры — теоретическом фундаменте похожести данных;
- Оптимальном методе в смысле раундов коммуникации;
- Редукции дисперсии в условиях похожести данных — рассмотрим оптимальный метод в смысле количества коммуникаций;
- Актуальных направлениях исследований вокруг похожести.

Дата: 4 декабря 15:30.

6. Стохастический градиентный спуск как стохастический процесс: базовые принципы и новые идеи.

Докладчик: Игорь Игнашин.

Стохастический градиентный спуск — один из фундаментальных методов обучения нейронных сетей. Его обычно воспринимают как простой алгоритм обновления весов

по мини-батчам, однако за этим стоит более глубокий взгляд: SGD можно рассматривать как дискретный стохастический процесс, эволюционирующий во времени. На семинаре мы разберём базовую формальную запись SGD и увидим, как из неё возникает представление об обучении как о динамической системе. Поймём, откуда появляется «шум» — почему выбор мини-батча приводит к случайным колебаниям параметров, и как этот шум зависит от шага обучения и структуры задачи.

Обсудим популярную интуицию, что SGD похож на броуновское движение с гауссовским шумом, и разберём, какие аргументы стоят за этим приближением. Покажем, как в некоторых работах пытаются аппроксимировать шум SGD нормальным распределением — например, поворачивая пространство параметров в удобный базис.

Затем мы посмотрим, почему эта картина оказывается неполной. На простых примерах увидим, что реальный шум SGD ведёт себя иначе, чем гауссовский: зависит от направления, от кривизны ландшафта и даже от величины шага обучения. В практической части сравним искусственно зашумлённые траектории с реальными траекториями SGD и увидим ключевые различия.

Дата: 5 декабря 17:05.