

Л13 Седловые задачи

Рассмотрим задачу условной оптимизации вида:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = \overline{1, m} \\ & Ax = b, \end{aligned} \tag{Л13.1}$$

где $A \in \mathbb{R}^{n \times d}$ и $b \in \mathbb{R}^n$. Дополнительно ещё можно было обобщить постановку и добавить, что $x \in \mathcal{X}$.

Функция Лагранжа для этой задачи строится следующим образом:

$$\mathcal{L}(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \nu^\top (Ax - b).$$

В Параграфе С7 была определена двойственная функция к задаче (Л13.1):

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda, \nu).$$

Далее из Утверждении С7.2 для всех $\lambda \succeq 0$ и $\nu \in \mathbb{R}^n$ имеем:

$$g(\lambda, \nu) \leq f(x^*).$$

Также сформулировано условие Слейтера (Утверждение С7.3).

Утверждение Л13.1. Рассмотрим задачу (Л13.1) с выпуклыми функциями $f_0, \dots, f_n$. Если существует такой $\bar{x} \in \mathbb{R}^d$, что выполняется условие Слейтера:

$$f_i(\bar{x}) < 0, \quad i = \overline{1, m}, \quad A\bar{x} = b,$$

то для задачи (Л13.1) выполняется сильная двойственность:

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} g(\lambda, \nu) = f_0(x^*).$$

Л13.1 Седловая точка Лагранжиана

Для того чтобы объединить прямую и двойственную задачу, определим понятие седловой точки лагранжиана.

Определение Л13.1. Точка $(x^*, \lambda^*, \nu^*) \in \mathbb{R}^d \times \mathbb{R}_+^m \times \mathbb{R}^n$ называется *седловой* для функции $\mathcal{L}(x, \lambda, \nu)$, если для любых $(x, \lambda, \nu) \in \mathbb{R}^d \times \mathbb{R}_+^m \times \mathbb{R}^n$ выполнено

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Теперь покажем, как связаны седловая точка лагранжиана и решение прямой задачи (Л13.1).

Теорема Л13.1. (Теорема о седловой точке Куна–Таккера)

Пусть для задачи выпуклой оптимизации (Л13.1) с выпуклыми функциями $f_0, \dots, f_n$ выполняется условие Слейтера (Утверждение Л13.1). Тогда следую-

щие утверждения эквиваленты:

- Для x^* существует $\lambda^* \succeq 0$ и $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа,
- x^* — глобальное решение задачи оптимизации с ограничениями.

Доказательство. $\Rightarrow$ Пусть для x^* существует $\lambda^* \succeq 0$, $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Для начала удостоверимся, что x^* удовлетворяет ограничениям. Если нет, то либо $Ax^* \neq b$, либо $f_i(x^*) > 0$. Рассмотрим случай, когда нарушается ограничение вида неравенства. Тогда

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu) = +\infty,$$

что невозможно, так как второе неравенство в определении седловой точки рушится для $\lambda = (\lambda_1^*, \dots, \lambda_{i-1}^*, 2\lambda_i^*, \lambda_{i+1}^*, \dots, \lambda_n^*)^\top$. Аналогично разбирается случай, когда нарушается $Ax^* \neq b$.

Теперь поскольку решение x^* удовлетворяет всем ограничениям, то

$$f_0(x^*) = \sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu).$$

Второе неравенство в определении седловой точки даёт:

$$\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Первое неравенство из определения седловой задачи даёт:

$$f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Остаётся заметить, что для допустимых x ограничения выполнены, а λ_i^* неотрицательные. Поэтому получаем, что левая часть не превосходит $f_0(x)$:

$$f_0(x) \geq f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq f_0(x^*).$$

$\Leftarrow$ Пусть x^* — глобальное решение задачи с ограничениями. Условие Слейтера (Утверждение Л13.1) нам даёт:

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

С одной стороны, поскольку x^* — допустимое решение, то оно удовлетворяет всем ограничениям. Поэтому выполняется неравенство:

$$f_0(x^*) \geq f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \nu^\top (Ax^* - b) = \mathcal{L}(x^*, \lambda, \nu),$$

где $\lambda \succeq 0$, $\nu \in \mathbb{R}^n$. С другой стороны, по определению двойственной функции:

$$g(\lambda^*, \nu^*) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^*, \nu^*) \leq \mathcal{L}(x^*, \lambda^*, \nu^*).$$

Заметим, что $\lambda_i^* f_i(x^*) = 0$ и $Ax^* - b = 0$. Поэтому $\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*)$. Собираем все неравенства вместе:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq g(\lambda^*, \nu^*) = f_0(x^*) = \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

■

На самом деле, седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения. Абстрагируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Рассмотрим следующую игровую интерпретацию:

- Пусть есть два игрока: первый выбирает $x \in \mathcal{X}$, а второй — $\lambda \in \Lambda$. В конкретной задаче это может означать, например, распределение ресурсов, выбор стратегии или управление параметрами.
- Функция $\mathcal{L}(x, \lambda)$ описывает значение прибыли, зависящей от выбранных x и λ . Первый игрок выплачивает второму сумму $\mathcal{L}(x, \lambda)$, то есть первый стремится минимизировать эту величину, а второй — максимизировать.
- Задача заключается в поиске равновесия между игроками, поскольку экстремальные стратегии не всегда оказываются оптимальными. Например, если второй игрок знает, что при некотором $\tilde{x}$ первый особенно уязвим, он может подобрать $\lambda(\tilde{x})$, при котором его выигрыш будет очень велик. Однако если при других $x \neq \tilde{x}$ та же стратегия $\lambda(\tilde{x})$ не приносит выгоды (даёт нулевой выигрыш), первый игрок просто перестанет выбирать $\tilde{x}$. С другой стороны, может существовать стратегия $\tilde{\lambda}$, обеспечивающая второму игроку небольшой, но стабильный выигрыш при любых x . В этом случае $\tilde{\lambda}$ окажется более рациональным выбором. Именно такие сбалансированные решения и определяются как равновесие.
- С точки зрения седловой задачи, равновесие (x^*, λ^*) является седловой точкой функции $\mathcal{L}$. То есть, для любых значений $x \in \mathcal{X}$, $\lambda \in \Lambda$:

$$\mathcal{L}(x, \lambda^*) \geq \mathcal{L}(x^*, \lambda^*) \geq \mathcal{L}(x^*, \lambda).$$

Получается следующее. Пусть $(\tilde{x}, \tilde{\lambda})$ — седловая точка. Тогда любые изменения x со стороны первого игрока приведут к увеличению его выплат (то есть к большему значению $\mathcal{L}$), а любые изменения λ со стороны второго игрока — к уменьшению его выигрыша.

В обратную сторону: если, например, $\tilde{x}$ не является частью седлового решения, то при фиксированной $\tilde{\lambda}$ первый игрок может изменить x так, чтобы платить меньше. Это нарушает равновесие, и значит, $(\tilde{x}, \tilde{\lambda})$ не является седлом.

Рассмотрим теперь вопрос: одинаковым ли будет результат игры, если

1. Сначала выбирает первый игрок, а затем второй;
2. Сначала выбирает второй игрок, а затем первый?

Ответ отрицательный, результаты будут различаться.

Если первым ходит игрок 1, он рассуждает так: «если я выберу некоторое x , то второй игрок сразу после этого выберет λ , максимизирующую его выигрыш: $\sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$. Значит, мне нужно выбрать x так, чтобы минимизировать свои потери:»

$$\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

В противоположной ситуации, когда первым выбирает игрок 2, результат определяется выражением

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda).$$

Используя эту интуицию, можно понять, что в общем случае выполняется неравенство

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) \leq \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Формально это следует из следующего рассуждения:

$$\inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) \leq \mathcal{L}(x, \lambda) \quad \forall x \in \mathcal{X} \implies \sup_{\lambda \in \Lambda} \inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) \leq \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda) \quad \forall x \in \mathcal{X},$$

откуда действительно следует

$$\sup_{\lambda \in \Lambda} \inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) \leq \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Как две игры: $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ связаны с седловой точкой?

Теорема Л13.2. Множество седловых точек функции $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непустое тогда и только тогда, когда обе задачи $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ имеют решения и эти решения совпадают.

Теорема Л13.3. Пусть $\mathcal{X}$, Λ выпуклые компактные множества, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда $\mathcal{L}$ имеет седловые точки на $\mathcal{X} \times \Lambda$.

Теорема Л13.4. Пусть $\mathcal{X}$, Λ выпуклые множества, и $\mathcal{X}$ или Λ дополнительно компактно, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда (гарантий существования тут нет)

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) = \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Л13.2 Метод градиентного спуска–подъёма

Оптимизация функции Лагранжа — седловая задача. Седловые задачи возникают как отдельный большой класс задач. Будем рассматривать следующую задачу:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^d} \mathcal{L}(x, \lambda), \quad (\text{Л13.2})$$

где $\mathcal{L}$ непрерывно дифференцируема по обоим группам переменных и выпукла–вогнута: выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x), а также градиенты $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ липшицевы с константой $\frac{L}{\sqrt{2}}$:

$$\begin{aligned} \|\nabla_x \mathcal{L}(x_1, \lambda_1) - \nabla_x \mathcal{L}(x_2, \lambda_2)\|_2^2 &\leq \frac{L^2}{2} \left(\|x_1 - x_2\|_2^2 + \|\lambda_1 - \lambda_2\|_2^2 \right), \\ \|\nabla_\lambda \mathcal{L}(x_1, \lambda_1) - \nabla_\lambda \mathcal{L}(x_2, \lambda_2)\|_2^2 &\leq \frac{L^2}{2} \left(\|x_1 - x_2\|_2^2 + \|\lambda_1 - \lambda_2\|_2^2 \right). \end{aligned}$$

Первый метод, который приходит в голову для решения седловой задачи — это метод спуска–подъёма. Он бывает одновременный (Simultaneous Gradient Descent–Ascent) и поочередный (Alternating Gradient Descent–Ascent). Одновременный выглядит следующим образом:

Алгоритм Л13.1 Метод одновременного градиентного спуска–подъёма (Sim–GDA)

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$ 
3:    $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^k, \lambda^k)$ 
4: end for
Выход:  $x^K, \lambda^K$ 

```

То есть, обновления переменных происходят с использованием градиентов из одной и той же точки, можно сказать одновременно.

Одновременные обновления просты в анализе. В случае отсутствия ограничения в виде одновременного обновления переменных, лучше показывает себя метод поочередного градиентного спуска–подъёма (Alt–GDA). Поочередные обновления сильно усложняют анализ сходимости. Идея же очень проста — сначала делаем шаг по одной переменной, а потом из новой точки по второй переменной.

Алгоритм Л13.2 Метод поочередного градиентного спуска–подъёма (Alt–GDA)

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$ 
3:    $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1}, \lambda^k)$ 
4: end for
Выход:  $x^K, \lambda^K$ 

```

К сожалению, метод градиентного спуска–подъёма (и одновременный, и поочередный) порой не сходится в не сильно выпуклых–сильно вогнутых задачах. Например, при решении задачи

$$\min_{x \in R} \max_{\lambda \in \mathbb{R}} x\lambda$$

со стартовой для алгоритма точкой $(1, 1)$. Седловой точкой является точка $(0, 0)$. Сгенерированные обоими алгоритмами точки можно посмотреть на Рисунке Л13.1.

Как видно, Alt–GDA начал двигаться по кругу, а Sim–GDA вообще стал расходиться. Однако, в сильно выпуклых–сильно вогнутых задачах, оба алгоритма сходятся гарантированно. Одновременный с итерационной скоростью $\mathcal{O}\left(\frac{L^2}{\mu^2}\right)$, а поочередный со скоростью $\mathcal{O}\left(\frac{L}{\mu}\right)$, что является оптимальным результатом. В остальных случаях (не учитывая конкретные задачи), сходимость поочередного градиентного спуска–подъёма не обязательно достигает оптимальных результатов (если метод вообще сойдется).

Л13.3 Экстраградиентный метод

Идея поочередного спуска–подъёма проста в понимании, реализации, и вполне неплохо работает, но с рядом упомянутых выше проблем. Все они решаются в экстраградиентном методе. В некоторой точке (x^k, λ^k) , алгоритм делает одновременный спуск–подъем




Рис. Л13.1: Sim-GDA и Alt-GDA для $\mathcal{L}(x, \lambda) = x\lambda$.

в промежуточную точку $(x^{k+1/2}, \lambda^{k+1/2})$. Затем, алгоритм делает одновременный спуск-подъем из точки (x^k, λ^k) , используя градиенты в $(x^{k+1/2}, \lambda^{k+1/2})$. Обычный градиентный спуск-подъем часто расходится. Более того, если алгоритм и сходится, то делает это в виде вихря, что сильно замедляет сходимость. Экстраградиентный метод решает это «толчком» в направлении решения, используя для движения градиенты не из текущей точки, а из «следующей».

Алгоритм Л13.3 Экстраградиентный метод

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: $x^{k+1/2} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$
 - 3: $\lambda^{k+1/2} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^k, \lambda^k)$
 - 4: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2})$
 - 5: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2})$
 - 6: **end for**
- Выход:** $\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}$
-

Теперь, когда мы исправили все недостатки метода поочередного спуска-подъёма, можно перейти к теоретическим выкладкам по методу экстраградиента. Для начала нам понадобится утверждение.

Утверждение Л13.2. Пусть $z, y \in \mathbb{R}^d$, и $z^+ = z - y$, тогда для любого $u \in \mathbb{R}^d$:

$$\|z^+ - u\|_2^2 = \|z - u\|_2^2 - 2\langle y, z^+ - u \rangle - \|z^+ - z\|_2^2.$$

Доказательство. Тут достаточно обычных алгебраических преобразований:

$$\begin{aligned}
\|z^+ - u\|_2^2 &= \|z^+ - z + z - u\|_2^2 \\
&= \|z - u\|_2^2 + 2\langle z^+ - z, z - u \rangle + \|z^+ - z\|_2^2 \\
&= \|z - u\|_2^2 + 2\langle z^+ - z, z - z^+ + z^+ - u \rangle + \|z^+ - z\|_2^2 \\
&= \|z - u\|_2^2 + 2\langle z^+ - z, z^+ - u \rangle - \|z^+ - z\|_2^2 \\
&= \|z - u\|_2^2 - 2\langle y, z^+ - u \rangle - \|z^+ - z\|_2^2.
\end{aligned}$$

■

Используя это утверждение, докажем теорему о сходимости метода.

Теорема Л13.5. Пусть седловая задача (Л13.2) с L -гладкой, выпукло-вогнутой функцией $\mathcal{L} : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью экстраградиентного метода (Алгоритм Л13.3). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ для любого $u \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}. \quad (\text{Л13.3})$$

Доказательство. Для удобства введем вектор переменных z и оператор:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

Если $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ L -липшицевы, то L -липшицев и оператор F . Как проявляется выпуклость по x и вогнутость по λ увидим позже. В новых обозначениях:

$$\begin{aligned}
z^{k+1/2} &= z^k - \gamma F(z^k), \\
z^{k+1} &= z^k - \gamma F(z^{k+1/2}).
\end{aligned}$$

Применим Утверждение Л13.2 два раза для итерации экстраградиентного метода:

- Для $z = z^k$, $y = \gamma F(z^{k+1/2})$ и $z^+ = z^{k+1}$:

$$\|z^{k+1} - u\|_2^2 = \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle - \|z^{k+1} - z^k\|_2^2.$$

- Для $z = z^k$, $y = \gamma F(z^k)$ и $z^+ = z^{k+1/2}$:

$$\|z^{k+1/2} - \tilde{u}\|_2^2 = \|z^k - \tilde{u}\|_2^2 - 2\gamma \langle F(z^k), z^{k+1/2} - \tilde{u} \rangle - \|z^{k+1/2} - z^k\|_2^2.$$

Подставим вместо $\tilde{u} = z^{k+1}$ и сложим:

$$\begin{aligned}
\|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle \\
&\quad - 2\gamma \langle F(z^k), z^{k+1/2} - z^{k+1} \rangle - \|z^{k+1/2} - z^k\|_2^2.
\end{aligned}$$

Перегруппируем слагаемые:

$$\begin{aligned}
\|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 + 2\gamma \langle F(z^{k+1/2}) - F(z^k), z^{k+1/2} - z^k \rangle \\
&\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2.
\end{aligned}$$

Оценим первое скалярное произведение:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &\quad + \|z^{k+1/2} - z^{k+1}\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \\ &\quad - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Слагаемое $\|z^{k+1/2} - z^{k+1}\|_2^2$ уничтожается с обеих сторон:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Используем L -липшицевость F :

$$\begin{aligned} \|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 L^2 \|z^k - z^{k+1/2}\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2 \\ &= \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle + (\gamma^2 L^2 - 1) \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Учтём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\|z^{k+1} - u\|_2^2 \leq \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle.$$

Эквивалентная запись неравенства:

$$2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Рассмотрим левую часть, оценим её снизу:

$$\begin{aligned} \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle &= \left\langle \begin{pmatrix} \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) \\ -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) \end{pmatrix}, \begin{pmatrix} x^{k+1/2} \\ \lambda^{k+1/2} \end{pmatrix} - \begin{pmatrix} u_x \\ u_\lambda \end{pmatrix} \right\rangle \\ &= \langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \rangle \\ &\quad + \langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \rangle. \end{aligned}$$

Применим выпуклость по x и вогнутость по λ :

$$\begin{aligned} \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle &= \langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \rangle \\ &\quad + \langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \rangle \\ &\geq \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) - \mathcal{L}(u_x, \lambda^{k+1/2}) \\ &\quad - \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) + \mathcal{L}(x^{k+1/2}, u_\lambda). \end{aligned}$$

В итоге получаем:

$$2\gamma (\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2})) \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Суммируем по всем k от 0 до $K-1$ и делим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2})) \leq \frac{\|z^0 - u\|_2^2 - \|z^K - u\|_2^2}{2\gamma K} \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

Неравенство Йенсена для выпуклой и вогнутой функции даёт:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

■

Что подставлять в качестве $u = (u_x, u_\lambda)^\top$ в критерий сходимости? Ожидаемый вариант:

$$\mathcal{L}(x^k, \lambda^*) - \mathcal{L}(x^*, \lambda^k),$$

где x^* и λ^* — решение седловой задачи. Покажем, почему такой выбор не самый удачный. Для этого рассмотрим простую седловую задачу:

$$\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1).$$

Предположим, что $1 \in \mathcal{X}$, $-1 \in \Lambda$, тогда решение этой задачи — $x^* = 1$, $\lambda^* = -1$ и $\mathcal{L}(1, -1) = 0$. Значение полученного критерия получится следующим:

$$\mathcal{L}(x, \lambda^*) - \mathcal{L}(x^*, \lambda) = 0.$$

Таким образом, такой критерий не подходит для выпукло-вогнутых седел, но подходит для сильно выпукло-сильно вогнутых. Но в сильно выпуклом-сильно вогнутом случае можно доказать линейную сходимость по аргументу, что более сильный результат. Правильный вариант критерия сходимости выглядит так:

$$\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k).$$

Сформулируем для него и оптимального значения шага следствие из теоремы.

Утверждение Л13.3. Пусть задача удовлетворяет условиям Теоремы Л13.5 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\max_{u_\lambda \in \mathbb{R}^d} \mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \min_{u_x \in \mathbb{R}^d} \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{L\|z^0 - u\|_2^2}{2K}. \quad (\text{Л13.4})$$

Более того, чтобы добиться точности ε по критерию выше, необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.} \quad (\text{Л13.5})$$

Доказательство. Оценка (Л13.4) напрямую следует из утверждения Теоремы Л13.5: подставляем в Неравенство (Л13.3) шаг $\gamma = \frac{1}{L}$, а также берем от левой части max по u_x и u_λ .

Вторая часть утверждения получается из первой. Ограничим правую часть Неравенства (Л13.4) положительным ε :

$$\frac{L\|z^0 - u\|_2^2}{2K} \leq \varepsilon.$$

Отсюда и получается оценка (Л13.5).

■

Стоит заметить, что переход к максимуму в критерии сходимости корректно определен только на компакте. Кажется, что это означает, что выпукло-вогнутые седловые задачи можно решать только на компактах (об этом говорила теорема Сиона–Какутани). Такую же проблему встречали и в выпуклой минимизации (на $\mathbb{R}^d$ выпуклая задача может не иметь решения). Поэтому мы предполагали, что решение существует. Здесь можно сделать то же самое: предположим что решение существует и лежит в некотором компактном множестве $\mathcal{X}_* \times \Lambda_*$, тогда в критерии сходимости можно брать $\Lambda = \Lambda_*$ и $\mathcal{X} = \mathcal{X}_*$.

Упомянем также, что в методе экстраградиента можно как итоговую точку использовать не среднее всех полученных точек, а лишь последнюю. Но в этом случае сходимость будет хуже — $\mathcal{O}\left(\frac{1}{\sqrt{K}}\right)$. Взглянем наглядно, какие точки выдают оба алгоритма на все той же задаче

$$\min_{x \in R} \max_{\lambda \in \mathbb{R}} x\lambda.$$

Результат на Рисунке Л13.2.




Рис. Л13.2: Экстраградиентный метод с разным выходом на задаче поиска седловой точки функции $\mathcal{L}(x, \lambda) = x\lambda$.

Теоретически, алгоритм, выдающий последнюю точку как результат должен быть хуже, но конкретно в этой задаче получилось наоборот.

Л13.4 Модификации экстраградиентного метода

Продолжим использовать следующую нотацию:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

Как ранее было сказано, что мы можем рассматривать экстраградиентный метод, когда $x \in \mathcal{X} \neq \mathbb{R}^d$ и $\lambda \in \Lambda \neq \mathbb{R}^n$. Тогда, $z \in \mathcal{Z} = \mathcal{X} \times \Lambda$. Тогда экстраградиентный метод можно рассматривать как метод с проекцией:

Алгоритм Л13.4 Экстраградиентный метод с проекциями

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^k)]$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

Алгоритм 2 раза выполняется оператор проекции и 2 раза вызывает оракул, то есть считается градиент. Это проблемы в случаях, когда оператор проекции или, вызов оракула стоят дорого. В особенности важен второй случай, так как большинство операций проекции не очень сложны. Например, в глубоком обучении ограничений чаще всего вообще нет, зато подсчёт градиента — весьма нелёгкая операция. Поэтому, в зависимости от проблемы, возникает необходимость получить метод, который будет или реже вызывать оракул, или реже делать проекции, или и то и другое.

Начнем с алгоритма под названием Past Extra-Gradient, опубликованный Леонидом Поповым в 1978 году:

Алгоритм Л13.5 Past Extra-Gradient

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k-1/2})]$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

В нём в первом шаге используется уже посчитанное значение оракула в точке $z^{k-1/2}$ как приближение оракула в точке z^k , которое неизвестно. Техника называется экстраполяцией из прошлого. Таким образом, мы вызываем оракул лишь раз за итерацию. Другую технику можно увидеть в алгоритме Reflected Gradient, которая дополнительно улучшает Экстраградиентный метод (Алгоритм Л13.3:

Алгоритм Л13.6 Reflected Gradient

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = z^k - (z^{k-1} - z^k)$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

Здесь, вместо подсчета оракула в точке z^k используется приближение разницей $\frac{z^{k-1} - z^k}{\gamma}$. Reflected в названии взято из первого шага, где наблюдается эффект «отражения» точки z^{k-1} относительно точки z^k . Заметим, что больше нет проекции в первом шаге. Более того, в этой версии алгоритма удобно использовать непостоянный шаг обучения, ведь он используется лишь в одной строке. Теперь, стоимость итерации этого алгоритма 1 проекция и 1 вызов оракула.

Далее идет алгоритм Пола Ценга с еще одной техникой, который порой называют еще Forward–Backward–Forward Algorithm:

Алгоритм Л13.7 Forward–Backward–Forward Algorithm

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^k)]$ 
3:    $z^{k+1} = z^{k+1/2} + \gamma_k F(z^k) - \gamma_k F(z^{k+1/2})$ 

```

```

4: end for

```

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

В этом алгоритме 2 вызова оракула и 1 вызов проекции. Мы его привели чтобы показать, что изменения можно вводить не только в первом шаге, но и во втором, как в методе Ценга. Здесь z^k приближается выражением $z^{k+1/2} + \gamma_k F(z^k)$, и снова нет проекции. Можно добавить идею из Алгоритма Л13.5, заменив z^k на $z^{k-1/2}$. Получится метод Ценга с экстраполяцией из прошлого, или метод Optimistic Gradient. У него ценность снова оптимальная — 1 проекция и 1 оракул.

Алгоритм Л13.8 Optimistic Gradient

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k-1/2})]$ 
3:    $z^{k+1} = z^{k+1/2} - \gamma_k (F(z^{k+1/2}) - F(z^{k-1/2}))$ 

```

```

4: end for

```

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

Обратим внимание, что при отсутствии проекций (то есть, при решении задачи без ограничений), все эти алгоритмы идентичны друг другу.

Приведены не все алгоритмы. Но получаются они путем комбинаций разных техник, которые и были описаны. Доказано, что все алгоритмы выше в выпукло-вогнутых гладких седловых задачах сходятся так же со скоростью $\frac{1}{K}$, как и экстраградиентный метод. Однако, разные ограничения на γ . Если для экстраградиентного метода $\gamma \leq \frac{1}{L}$,

то, например, для Reflected Gradient $\gamma \leq \frac{\sqrt{2}-1}{L}$.

При изучении метода тяжелого шарика (Алгоритм Л4.1) возник моментум, который улучшает физику обычного градиентного спуска. При решении седловых задач было показано, что моментум также позволяет немного ускорить алгоритмы. Однако, моментум не всегда должен быть положительным, зависит от метода. У всех алгоритмов для решения седловых задач есть особенность, что они идут к решению вихрем. Моментум позволяет нам уменьшить вихрение. В случае экстраградиентного метода, моментум вставляется во второй шаг с положительным значением.

Алгоритм Л13.9 Экстраградиентный метод с моментумом

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметры моментума $\{\tau_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = \Pi_{\mathcal{Z}} [z^k - \gamma_k F(z^k)]$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}} [z^k - \gamma_k F(z^{k+1/2}) + \tau_k (z^k - z^{k-1})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

В Alt-GDA хорошо показывает себя именно отрицательный моментум, то есть когда $\tau_k < 0$:

Алгоритм Л13.10 Alt-GDA с отрицательным моментумом

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметры моментума $\{\tau_k\}_{k=0} < 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k) + \tau_k (x^k - x^{k-1})$
- 3: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1}, \lambda^k) + \tau_k (\lambda^k - \lambda^{k-1})$
- 4: **end for**

Выход: x^K, λ^K

Разница в том, какой моментум использовать, вызвана тем, что экстраградиентный метод и обычные градиентные методы работают совсем по-разному физически.

Л13.5 Прямо-двойственный метод

Рассмотрим задачу минимизации с ограничениями вида равенств:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & Ax = b. \end{aligned}$$

Лагранжиан такой задачи:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^n} \quad \mathcal{L}(x, \lambda) = f(x) - \lambda^\top Ax.$$

Пойдем дальше и рассмотрим задачу минимизации с регуляризатором:

$$\min_{x \in \mathbb{R}^d} f(x) + g(Ax).$$

Заметим, что выпуклой и замкнутой функции:

$$g(Ax) = g^{**}(Ax) = \max_{\lambda \in \mathbb{R}^n} \{(Ax)^\top \lambda - g^*(\lambda)\},$$

тогда получаем следующую задачу:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^n} \quad \mathcal{L}(x, \lambda) = f(x) - \lambda^\top Ax - g(\lambda). \quad (\text{Л13.6})$$

Дополнительно потребуем, чтобы функция f была L_f -гладкой и выпуклой, а функция g была L_g -гладкой и выпуклой.

Алгоритм Л13.11 Прямо-двойственный алгоритм

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**
2: $x^{k+1} = x^k - \gamma_k (\nabla f(x^k) - A^\top \lambda^k)$
3: $\lambda^{k+1} = \lambda^k - \gamma_k (\nabla g(\lambda^k) + A(2x^{k+1} - x^k))$
4: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K \lambda^k$

Если вместо $(2x^{k+1} - x^k)$ подставить просто x^k получится просто спуск-подъём. В $(2x^{k+1} - x^k)$ защита «экстраградиентность».

Теорема Л13.6. Пусть седловая задача (Л13.6) с выпуклой L_f -гладкой функцией $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и выпуклой L_g -гладкой функцией $g : \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью прямо-двойственного метода (Алгоритм Л13.11). Тогда при $\gamma_k = \gamma \leq \frac{1}{\max(L_g, L_f) + \|A\|_2}$ для любых $u = (x, \lambda) \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1}\right) \leq \frac{\|z^0 - u\|_P^2}{2K}.$$

Доказательство. Распишем разность:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &= f(x^{k+1}) - f(x) - (\lambda^{k+1})^\top A(x^{k+1} - x) \\ &= f(x^{k+1}) - f(x^k) + f(x^k) - f(x) \\ &\quad - (\lambda^{k+1})^\top A(x^{k+1} - x). \end{aligned}$$

Воспользуемся выпуклостью и гладкостью f :

$$f(x^{k+1}) - f(x^k) \leq \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2.$$

Воспользуемся выпуклостью f :

$$f(x^k) - f(x) \leq \langle \nabla f(x^k), x^k - x \rangle.$$

Объединяя полученные результаты, получаем:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x). \end{aligned}$$

Подставим шаг:

$$\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \rangle = \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle.$$

В итоге имеем:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x). \end{aligned}$$

Распишем разность:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &= g(\lambda^{k+1}) - g(\lambda) - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}) \\ &= g(\lambda^{k+1}) - g(\lambda^k) + g(\lambda^k) - g(\lambda) \\ &\quad - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}).\end{aligned}$$

Воспользуемся выпуклостью и гладкостью g :

$$g(\lambda^{k+1}) - g(\lambda^k) \leq \langle \nabla g(\lambda^k), \lambda^{k+1} - \lambda^k \rangle + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2.$$

Воспользуемся выпуклостью f :

$$g(\lambda^k) - g(\lambda) \leq \langle \nabla g(\lambda^k), \lambda^k - \lambda \rangle.$$

Объединяя полученные результаты, получаем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \rangle \\ &\quad + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda).\end{aligned}$$

Подставим шаг:

$$\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \rangle = \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle.$$

В итоге имеем:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda).\end{aligned}$$

Просуммируем два полученных неравенства:

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) &\leq \begin{pmatrix} x^k - x^{k+1} \\ \lambda^k - \lambda^{k+1} \end{pmatrix}^\top \begin{pmatrix} \frac{1}{\gamma} I_d & A^\top \\ A & \frac{1}{\gamma} I_n \end{pmatrix} \begin{pmatrix} x^{k+1} - x \\ \lambda^{k+1} - \lambda \end{pmatrix} \\ &\quad + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 + \frac{Lf}{2} \|x^{k+1} - x^k\|_2^2.\end{aligned}$$

Введем обозначение:

$$P = \begin{pmatrix} \frac{1}{\gamma} I_d & A^\top \\ A & \frac{1}{\gamma} I_n \end{pmatrix},$$

тогда

$$\begin{aligned}\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) &\leq \langle z^k - z^{k+1}, z^{k+1} - z \rangle_P + \frac{\max(Lg, Lf)}{2} \|z^{k+1} - z^k\|_2^2 \\ &= \frac{1}{2} \|z^k - z\|_P^2 - \frac{1}{2} \|z^{k+1} - z\|_P^2 - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \\ &\quad + \frac{\max(Lg, Lf)}{2} \|z^{k+1} - z^k\|_2^2.\end{aligned}$$

Просуммируем по k от 0 до $K-1$:

$$\begin{aligned} \sum_{k=0}^{K-1} (\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1})) &\leq \frac{1}{2} \|z^0 - z\|_P^2 - \frac{1}{2} \|z^K - z\|_P^2 \\ &+ \sum_{k=0}^{K-1} \left(\frac{\max(L_g, L_f)}{2} \|z^{k+1} - z^k\|_2^2 - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \right). \end{aligned}$$

Потребуем $P \succ \max(L_g, L_f)I_{d+n}$, чтобы избавиться от последней строки и оставить $\|z^0 - z\|^2$. Это достигается при $\gamma \leq \frac{1}{\max(L_g, L_f) + \|A\|_2}$.

Делим на K и получаем

$$\frac{1}{K} \sum_{k=0}^{K-1} (\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1})) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

Неравенство Йенсена для выпуклой и вогнутой функции дает

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}, \lambda\right) - \mathcal{L}\left(x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1}\right) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

■

Список литературы

- [1] Necdet Serhat Aybat, Alireza Fallah, Mert Gurbuzbalaban, and Asuman Ozdaglar. A universally optimal multistage accelerated stochastic gradient method, 2019.
- [2] Francis Bach and Eric Moulines. Non-asymptotic analysis of stochastic approximation algorithms for machine learning. In *Advances in Neural Information Processing Systems*, volume 24, pages 451–459, December 2011.
- [3] Aleksandr Beznosikov, Valentin Samokhin, and Alexander Gasnikov. Distributed saddle point problems: lower bounds, near-optimal and robust algorithms*. *Optimization Methods and Software*, page 1–18, March 2025.
- [4] Stephen Boyd and Lieven Vandenbergh. *Convex Optimization*. Cambridge University Press, Cambridge, 2004.
- [5] Gábor Braun, Alejandro Carderera, Cyrille W Combettes, Hamed Hassani, Amin Karbasi, Aryan Mokhtari, and Sebastian Pokutta. Conditional gradient methods. *arXiv preprint arXiv:2211.14103*, 2022.
- [6] A. Cauchy. Méthode générale pour la résolution des systèmes d'équations simultanées. *Comptes rendus hebdomadaires des séances de l'Académie des sciences*, 55:536–538, 1847.
- [7] Yudong Chen. Lecture 9–10: Accelerated gradient descent, 2023. UW-Madison CS/ISyE/Math/Stat 726 Spring 2023 Lecture Notes.
- [8] Timothy Dozat. Incorporating nesterov momentum into adam. ICLR Workshop, 2016. OpenReview; NAdam method.