

Методы редукции дисперсии

Методы оптимизации

Александр Богданов

Московский физико-технический институт

13 мая 2026



Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.

Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.
- Рассмотрим методы, которые уменьшают её — **методы редукции дисперсии**.

Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.
- Рассмотрим методы, которые уменьшают её — **методы редукции дисперсии**.
- Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \right].$$

Задача

- До этого мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов.
- Рассмотрим методы, которые уменьшают её — **методы редукции дисперсии**.
- Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \right].$$

- Будем считать, что $\nabla f(x, \xi) = \nabla f_i(x)$, то есть выбор случайной реализации ξ эквивалентен выбору индекса i .

Почему стохастический градиентный спуск не сходится?

- На практике при использовании стохастического градиентного спуска с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск, однако вокруг минимума он начинает осциллировать. **Вопрос:** с чем это связано?

Почему стохастический градиентный спуск не сходится?

- На практике при использовании стохастического градиентного спуска с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск, однако вокруг минимума он начинает осциллировать. **Вопрос:** с чем это связано? В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума.

Почему стохастический градиентный спуск не сходится?

- На практике при использовании стохастического градиентного спуска с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск, однако вокруг минимума он начинает осциллировать. **Вопрос:** с чем это связано? В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума.
- Рассмотрим пример, пусть в задаче машинного обучения x^* минимизирует потери по всей выборке, а $f(x, \xi)$ отражает потери только на отдельном сэмпле ξ . Хотя x^* оптимальна в среднем, но нет никаких гарантий, что x^* оптимальна для отдельного элемента выборки. Поэтому в общем случае $\nabla f(x^*, \xi) \neq 0$, и возникает осциллирующий эффект.

Модификация стохастического градиентного спуска

- Аппроксимируем полный градиент g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \rightarrow x^*$, эта аппроксимация стремилась к нулю $g^k \rightarrow \nabla f(x^*) = 0$.

Модификация стохастического градиентного спуска

- Аппроксимируем полный градиент g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \rightarrow x^*$, эта аппроксимация стремилась к нулю $g^k \rightarrow \nabla f(x^*) = 0$.
- На каждой итерации такой метод производит шаг по g^k :

$$x^{k+1} = x^k - \gamma g^k.$$

Модификация стохастического градиентного спуска

- Аппроксимируем полный градиент g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \rightarrow x^*$, эта аппроксимация стремилась к нулю $g^k \rightarrow \nabla f(x^*) = 0$.
- На каждой итерации такой метод производит шаг по g^k :

$$x^{k+1} = x^k - \gamma g^k.$$

- g^k должны удовлетворять предположению несмещенности.

SAGA

Алгоритм SAGA

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
 - 3: $g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k$
 - 4: $y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & i = i_k \\ y_i^k, & i \neq i_k \end{cases}$
 - 5: $x^{k+1} = x^k - \gamma_k g^k$
 - 6: **end for**
- Ensure:** x^K
-

SAGA

Отметим, что аппроксиматор g^k обладает свойством несмещенности:

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n y_i^k + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).$$

Сходимость

Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k - \nabla f(x^*)\|_2^2.$$

Сходимость

Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k - \nabla f(x^*)\|_2^2.$$

Возьмем условное математическое ожидание по случайности на итерации k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} \left[g^k \mid x^k \right], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k - \nabla f(x^*)\|_2^2 \mid x^k \right]. \end{aligned}$$

Сходимость

Рассмотрим слагаемое $\mathbb{E} [g^k \mid x^k]$:

$$\begin{aligned}\mathbb{E} [g^k \mid x^k] &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k \mid x^k \right] \\ &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k \mid x^k \right] + \frac{1}{n} \sum_{i=1}^n y_i^k \\ &= \frac{1}{n} \sum_{i=1}^n \left(\nabla f_i(x^k) - y_i^k \right) + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).\end{aligned}$$

Сходимость

Рассмотрим $\mathbb{E} \left[\|g^k - \nabla f(x^*)\|_2^2 \mid x^k \right]$:

$$\begin{aligned} & \mathbb{E} \left[\|g^k - \nabla f(x^*)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) + \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Сходимость

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned} & \mathbb{E} \left[\left\| g^k - \nabla f(x^*) \right\|_2^2 \middle| x^k \right] \\ & \leq 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \right\|_2^2 \middle| x^k \right] \\ & \quad + 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \middle| x^k \right]. \end{aligned}$$

Сходимость

Заметим, что если во втором слагаемом взять ξ равным $\nabla f_{i_k}(x^*) - y_{i_k}^k$, то получим дисперсию $\mathbb{E} \left[\|\xi - \mathbb{E}[\xi \mid x^k]\|_2^2 \mid x^k \right]$.
Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\begin{aligned} \mathbb{E} \left[\left\| g^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right] &\leq 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \right\|_2^2 \mid x^k \right] \\ &\quad + 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^*) - y_{i_k}^k \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Сходимость

Раскроем математическое ожидание, пользуясь гладкостью и выпуклостью f_i :

$$\begin{aligned} & \mathbb{E} \left[\left\| g^k - \nabla f(x^*) \right\|_2^2 \middle| x^k \right] \\ & \leq 4L \cdot \frac{1}{n} \sum_{i=1}^n \left(f_i(x^k) - f_i(x^*) - \left\langle \nabla f_i(x^*), x^k - x^* \right\rangle \right) \\ & \quad + 2 \cdot \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2 \\ & = 4L \left(f(x^k) - f^* \right) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2. \end{aligned}$$

Сходимость

Собирая всё вместе, получаем:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \\ & \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ & \quad + \gamma^2 \left(4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2 \right). \end{aligned}$$

Сходимость

Собирая всё вместе, получаем:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \\ \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ + \gamma^2 \left(4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2 \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью функции f :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - 2\gamma L)(f(x^k) - f^*) \\ &\quad + 2\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2. \end{aligned}$$

Сходимость

Пришли к тому, что если $y_i^k \rightarrow f_i(x^*)$, то есть линейная сходимость.

Сходимость

Пришли к тому, что если $y_i^k \rightarrow f_i(x^*)$, то есть линейная сходимость.

Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] - 2\gamma(1 - 2\gamma L) \mathbb{E} \left[f(x^k) - f^* \right] \\ &\quad + 2\gamma^2 \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2 \right]. \end{aligned}$$

Сходимость

Пришли к тому, что если $y_i^k \rightarrow f_i(x^*)$, то есть линейная сходимость.

Возьмем полное математическое ожидание:

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] - 2\gamma(1 - 2\gamma L) \mathbb{E} \left[f(x^k) - f^* \right] \\ &\quad + 2\gamma^2 \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2 \right].\end{aligned}$$

Теперь рассмотрим, как ведет себя $\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^*) - y_i^k \right\|_2^2 \middle| x^k \right]$:

$$\begin{aligned}\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| y_i^{k+1} - \nabla f_i(x^*) \right\|_2^2 \middle| x^k \right] &= \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \left\| y_i^k - \nabla f_i(x^*) \right\|_2^2 \\ &\quad + \frac{1}{n} \cdot \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^*) \right\|_2^2.\end{aligned}$$

Сходимость

Воспользуемся выпуклостью и гладкостью f_i :

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| y_i^{k+1} - \nabla f_i(x^*) \right\|_2^2 \middle| x^k \right] \leq \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \left\| y_i^k - \nabla f_i(x^*) \right\|_2^2 + \frac{2L}{n} \left(f(x^k) - f^* \right).$$

Сходимость

Воспользуемся выпуклостью и гладкостью f_i :

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| y_i^{k+1} - \nabla f_i(x^*) \right\|_2^2 \middle| x^k \right] \leq \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \left\| y_i^k - \nabla f_i(x^*) \right\|_2^2 + \frac{2L}{n} \left(f(x^k) - f^* \right).$$

Возьмем полное математическое ожидание:

$$\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| y_i^{k+1} - \nabla f_i(x^*) \right\|_2^2 \right] \leq \left(1 - \frac{1}{n} \right) \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \left\| y_i^k - \nabla f_i(x^*) \right\|_2^2 \right] + \frac{2L}{n} \mathbb{E} \left[f(x^k) - f^* \right].$$

Сходимость

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить».

Сходимость

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить». Возьмем $M > 0$ и сложим две рекурренты, которые получились выше:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + M\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \left(1 + \frac{2}{M} - \frac{1}{n} \right) \mathbb{E} \left[\frac{M\gamma^2}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ & \quad - 2\gamma \left(1 - 2\gamma L - \frac{\gamma ML}{n} \right) \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Сходимость

Возьмем $M = 4n$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \left(1 - \frac{1}{2n} \right) \mathbb{E} \left[4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ & \quad - 2\gamma(1 - 6\gamma L) \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Сходимость

Потребуем $\gamma \leq \frac{1}{6L}$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \mathbb{E} \left[\|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right]. \end{aligned}$$

Сходимость

Потребуем $\gamma \leq \frac{1}{6L}$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \mathbb{E} \left[\|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right]. \end{aligned}$$

- Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \rightarrow x^*$, так и $y_i^k \rightarrow \nabla f_i(x^*)$, что и закладывалось в метод.

Сходимость

Потребуем $\gamma \leq \frac{1}{6L}$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \mathbb{E} \left[\|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right]. \end{aligned}$$

- Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \rightarrow x^*$, так и $y_i^k \rightarrow \nabla f_i(x^*)$, что и закладывалось в метод.
- Из такой сходимости следует и сходимость по $\mathbb{E} \left[\|x^k - x^*\|_2^2 \right]$.

Сходимость

Теорема

Пусть задача безусловной стохастической оптимизации суммы с L -гладкими, выпуклыми функциями f_i и μ -сильно выпуклой целевой функцией f решается с помощью SAGA с $\gamma_k = \gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E}[V_k] \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\}^k \mathbb{E}[V_0],$$

где $V_k = \|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2$.

Более того, при оптимальном выборе шага для достижения точности ε необходимо

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right) \text{ итераций.}$$

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше?

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше? Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M . При этом сходимости лучше, чем $(1 - \frac{1}{n})$, не добиться.

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше? Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M . При этом сходимости лучше, чем $(1 - \frac{1}{n})$, не добиться.
- Получили следующую оценку на число итераций:

$$\mathcal{O}\left(\left\lceil n + \frac{L}{\mu} \right\rceil \log \frac{1}{\varepsilon}\right).$$

Сходимость

- **Вопрос:** почему не взять M огромным, тогда сходимость будет лучше? Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M . При этом сходимости лучше, чем $(1 - \frac{1}{n})$, не добиться.
- Получили следующую оценку на число итераций:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right).$$

- У классического градиентного спуска оценка:

$$\mathcal{O}\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right),$$

но оракульная сложность (подсчет градиентов ∇f_i) у градиентного спуска в n раз больше.

SVRG

- SAGA обладает существенным недостатком — требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы.

SVRG

- SAGA обладает существенным недостатком — требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы.
- Классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели.

SVRG

- SAGA обладает существенным недостатком — требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы.
- Классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели.
- Рассмотрим метод SVRG, который эффективно по памяти реализует идею редукции дисперсии. Основная идея этого метода заключается в том, чтобы уйти от запоминания стохастических градиентов по каждому индексу i . Вместо восстановления полного градиента с запозданием, как это делает SAGA, SVRG считает полный градиент раз в некоторое время. Такая точка называется **референсной**, а промежуток между подсчетами полного градиента — **эпохой**.

SVRG

Алгоритм SVRG

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```
1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:   for  $k = 0, 1, \dots, K - 1$  do
4:     Сгенерировать независимо  $i_k \sim U(\overline{1, n})$ 
5:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^t) + \nabla f(y^t)$ 
6:      $x^{k+1} = x^k - \gamma_k g^k$ 
7:   end for
8:    $y^{t+1} = x^K$ 
9: end for
Выход:  $y^T$ 
```

SVRG

- Аппроксиматор в SVRG несмещенный:

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

SVRG

- Аппроксиматор в SVRG несмещенный:

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

- Итерационная сложность сходимости метода — $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$ совпадает с SAGA.

SVRG

- Аппроксиматор в SVRG несмещенный:

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

- Итерационная сложность сходимости метода — $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$ совпадает с SAGA.
- Необходимость вычислять полный градиент даже раз в эпоху, а также два стохастических градиента на каждой итерации требуют дополнительных вычислительных мощностей.

SARAH

- Алгоритм SVRG эффективный по памяти и при этом не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода.

SARAH

- Алгоритм SVRG эффективный по памяти и при этом не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода.
- По этой причине, был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках.

SARAH

- Алгоритм SVRG эффективный по памяти и при этом не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода.
- По этой причине, был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках.
- SARAH использует идею рекурсивного накопления градиентов. Такая схема на каждой итерации добавляет к аппроксиматору направление градиента в новой точке, при этом вычитая старое направление. В то время как полный градиент в референсной точке из SVRG мешает сходиться к решению, добавляя вклад старого направления в текущий шаг, SARAH динамично подстраивает траекторию под правильное направление к минимуму.

SARAH

Алгоритм SARAH

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```
1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:    $g^{-1} = \nabla f(x^0)$ 
4:   for  $k = 0, 1, \dots, K - 1$  do
5:     Сгенерировать независимо  $i_k \sim U(\overline{1, n})$ 
6:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}$ 
7:      $x^{k+1} = x^k - \gamma_k g^k$ 
8:   end for
9:    $y^{t+1} = x^K$ 
10: end for
Ensure:  $y^K$ 
```

SARAH

- Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ.

SARAH

- Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ.
- SARAH все еще сохраняет идею редукции дисперсии: при $x^k \rightarrow x^*$ имеем, что $g^k \rightarrow 0$.

SARAH

- Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ.
- SARAH все еще сохраняет идею редукции дисперсии: при $x^k \rightarrow x^*$ имеем, что $g^k \rightarrow 0$.
- SARAH, аналогично SVRG имеет итерационную сложность $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$, а также требует периодического вычисления полного градиента и подсчета двух стохастических градиентов на каждой итерации. Тем не менее, SARAH решает проблему с нестабильной траекторией сходимости.

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.
- Обеспечивают сходимость, как у градиентного спуска:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right).$$

но в n раз дешевле (считаем не полный градиент, а только 1 слагаемое).

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.
- Обеспечивают сходимость, как у градиентного спуска:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right).$$

но в n раз дешевле (считаем не полный градиент, а только 1 слагаемое).

- Обладают недостатками: траты памяти, подсчет полного градиента.

Итог

- Методы редукции дисперсии предназначены для стохастических задач вида конечной суммы.
- Обеспечивают сходимость, как у градиентного спуска:

$$\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right).$$

но в n раз дешевле (считаем не полный градиент, а только 1 слагаемое).

- Обладают недостатками: траты памяти, подсчет полного градиента.
- Могут быть ускорены.