

Координатный спуск

Методы оптимизации

Александр Богданов

Московский физико-технический институт

13 мая 2026



Пример

Рассмотрим квадратичную задачу

$$\begin{aligned}\min_{x \in \mathbb{R}^d} f(x) &:= \frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} \sum_{i=1}^n (A_{i,:}x - b_i)^2 \\ &= \frac{1}{2} \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle x_j - \frac{1}{2} \langle b, Ax - b \rangle.\end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i -ая строка матрицы A , $A_{:,j}$ — j -ый столбец матрицы A , $b \in \mathbb{R}^n$ — метки.

Пример

Рассмотрим квадратичную задачу

$$\begin{aligned}\min_{x \in \mathbb{R}^d} f(x) &:= \frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} \sum_{i=1}^n (A_{i,:}x - b_i)^2 \\ &= \frac{1}{2} \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle x_j - \frac{1}{2} \langle b, Ax - b \rangle.\end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i -ая строка матрицы A , $A_{:,j}$ — j -ый столбец матрицы A , $b \in \mathbb{R}^n$ — метки.

Полный градиент в этой задаче имеет вид

$$\nabla f(x) = A^\top (Ax - b) = \sum_{i=1}^n A_{i,:}^\top (A_{i,:}x - b_i) = \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle e_j,$$

где e_j — j -ый базисный вектор.

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$\begin{aligned} g^k &= nA_{i_k,:}^\top (A_{i_k,:}x^k - b_{i_k}), \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$\begin{aligned} g^k &= nA_{i_k, :}^\top (A_{i_k, :} x^k - b_{i_k}), \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

- Этот шаг использует только одну строку матрицы A .

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$\begin{aligned} g^k &= n A_{i_k, :}^\top (A_{i_k, :} x^k - b_{i_k}), \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

- Этот шаг использует только одну строку матрицы A .
- Множитель n нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$.

Стохастический выбор строки

- На итерации k равновероятно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы:

$$\begin{aligned} g^k &= n A_{i_k, :}^\top (A_{i_k, :} x^k - b_{i_k}), \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

- Этот шаг использует только одну строку матрицы A .
- Множитель n нужен для несмещенности: $\mathbb{E} [g^k] = \nabla f(x^k)$.
- Стоимость одной итерации в n раз дешевле, чем полный градиент, так как выбирается 1 объект из суммы с n слагаемыми.

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$\begin{aligned} g^k &= d \langle Ax^k - b, A_{:,j_k} \rangle e_{j_k}, \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$\begin{aligned} g^k &= d \langle Ax^k - b, A_{:,j_k} \rangle e_{j_k}, \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

- Этот шаг использует только один столбец матрицы A .

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$\begin{aligned} g^k &= d \langle Ax^k - b, A_{:,j_k} \rangle e_{j_k}, \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

- Этот шаг использует только один столбец матрицы A .
- Множитель d нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$.

Стохастический выбор столбца

- На итерации k равновероятно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора:

$$\begin{aligned} g^k &= d \langle Ax^k - b, A_{:j_k} \rangle e_{j_k}, \\ x^{k+1} &= x^k - \gamma_k g^k. \end{aligned}$$

- Этот шаг использует только один столбец матрицы A .
- Множитель d нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$.
- Стоимость одной итерации в d раз дешевле, чем полный градиент, так как делается 1 скалярное произведение вместо d .

Координатный метод

Алгоритм Координатный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, d})$
- 3: $x^{k+1} = x^k - \gamma_k d[\nabla f(x^k)]_{i_k} e_{i_k}$
- 4: **end for**

Выход: x^K

Свойства стохастического градиента

Утверждение

Пусть индекс $i_k = \overline{1, d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняется:

$$\mathbb{E}[d[\nabla f(x)]_{i_k} e_{i_k}] = \nabla f(x), \quad \mathbb{E}\left[\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2\right] = d\|\nabla f(x)\|_2^2.$$

Свойства стохастического градиента

Утверждение

Пусть индекс $i_k = \overline{1, d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняется:

$$\mathbb{E}[d[\nabla f(x)]_{i_k} e_{i_k}] = \nabla f(x), \quad \mathbb{E}\left[\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2\right] = d\|\nabla f(x)\|_2^2.$$

Покажем первое равенство:

$$\mathbb{E}[d[\nabla f(x)]_{i_k} e_{i_k}] = \sum_{i=1}^d \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Свойства стохастического градиента

Утверждение

Пусть индекс $i_k = \overline{1, d}$ выбирается независимо и равновероятно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняется:

$$\mathbb{E}[d[\nabla f(x)]_{i_k} e_{i_k}] = \nabla f(x), \quad \mathbb{E}\left[\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2\right] = d\|\nabla f(x)\|_2^2.$$

Покажем первое равенство:

$$\mathbb{E}[d[\nabla f(x)]_{i_k} e_{i_k}] = \sum_{i=1}^d \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Покажем второе равенство:

$$\mathbb{E}\left[\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2\right] = \sum_{i=1}^d \frac{1}{d} d^2 [\nabla f(x)]_i^2 \|e_i\|_2^2 = d\|\nabla f(x)\|_2^2.$$

Сходимость

По определению итерации:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle d\left[\nabla f(x^k)\right]_{i_k} e_{i_k}, x^k - x^* \right\rangle \\ &\quad + \gamma^2 \left\| d\left[\nabla f(x^k)\right]_{i_k} e_{i_k} \right\|_2^2.\end{aligned}$$

Сходимость

По определению итерации:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle d[\nabla f(x^k)]_{i_k} e_{i_k}, x^k - x^* \right\rangle \\ &\quad + \gamma^2 \left\| d[\nabla f(x^k)]_{i_k} e_{i_k} \right\|_2^2.\end{aligned}$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned}\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 \\ &\quad - 2\gamma \left\langle \mathbb{E} \left[d[\nabla f(x^k)]_{i_k} e_{i_k} \mid x^k \right], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\left\| d[\nabla f(x^k)]_{i_k} e_{i_k} \right\|_2^2 \mid x^k \right].\end{aligned}$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \|\nabla f(x^k)\|_2^2.$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \left\| \nabla f(x^k) \right\|_2^2.$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - d\gamma L) (f(x^k) - f^*).$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \|\nabla f(x^k)\|_2^2.$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - d\gamma L) (f(x^k) - f^*).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое отрицательно, и остаётся

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2.$$

Сходимость

Воспользуемся свойством стохастического градиента:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \|\nabla f(x^k)\|_2^2.$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - d\gamma L) (f(x^k) - f^*).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое отрицательно, и остаётся

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2.$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

Сходимость

Теорема

Пусть задача безусловной оптимизации с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью координатного спуска. Тогда при $\gamma_k = \gamma \leq \frac{1}{dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность

$$\mathcal{O}\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right).$$

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность

$$\mathcal{O}\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском?

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность

$$\mathcal{O}\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность

$$\mathcal{O}\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.

- Координатный метод часто хорошо себя проявляет на практике.

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность

$$\mathcal{O}\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.

- Координатный метод часто хорошо себя проявляет на практике.
- Результат обобщается и на случай выбора нескольких координат.

Итог

- Подставив $\gamma = \frac{1}{dL}$, получаем следующую итерационную сложность

$$\mathcal{O}\left(\frac{dL}{\mu} \log \frac{1}{\varepsilon}\right).$$

Вопрос: есть ли улучшения по сравнению с обычным градиентным спуском? В общем случае нет.

- Координатный метод часто хорошо себя проявляет на практике.
- Результат обобщается и на случай выбора нескольких координат.
- Возможно ускорение с помощью двух моментумов.