

Л14 Методы редукции дисперсии

В Параграфе Л5 мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов. Рассмотрим методы, которые уменьшают ее — *методы редукции дисперсии*. Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \right].$$

Далее будем считать, что $\nabla f(x, \xi) = \nabla f_i(x)$, то есть выбор случайной реализации ξ эквивалентен выбору индекса i .

На практике при использовании стохастического градиентного спуска (Алгоритм Л5.1) с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск (Алгоритм Л3.1), однако вокруг минимума он начинает осциллировать. В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума. Рассмотрим пример, пусть в задаче машинного обучения x^* минимизирует потери по всей выборке, а $f(x, \xi)$ отражает потери только на отдельном сэмпле ξ . Хотя x^* оптимальна в среднем, но нет никаких гарантий, что x^* оптимальна для отдельного элемента выборки. Поэтому в общем случае $\nabla f(x^*, \xi) \neq 0$, и возникает осциллирующий эффект. Это приводит сразу к двум большим недостаткам стохастического градиентного спуска:

1. Метод не сходится к решению при константном γ , только лишь к его окрестности, размер которой зависит от дисперсии стохастических градиентов $\nabla f(x^*, \xi)$ и размера γ ;
2. Скорость сходимости метода даже с уменьшающимся шагом при оптимизации μ -сильно выпуклой целевой функции сублинейная [34].

Основная идея методов редукции дисперсии заключается в том, чтобы сконструировать аппроксимацию полного градиента g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \rightarrow x^*$, эта аппроксимация стремилась к нулю $g^k \rightarrow \nabla f(x^*) = 0$. На каждой итерации такой метод производит шаг по g^k :

$$x^{k+1} = x^k - \gamma g^k.$$

Прежде чем перейти к конкретным примерам выбора g^k , отметим, что все g^k должны удовлетворять предположению несмещенности (Предположение Л5.1). Начнем обзор конкретных методов с подходов, использующих несмещенные аппроксиматоры.

Л14.1 SAGA

Идея алгоритма SAGA заключается в том, что на каждой итерации k , считая стохастический градиент по индексу i_k , он сохраняет его в y_{i_k} , а затем использует y_i для конструкции аппроксиматора полного градиента.

Алгоритм Л14.1 SAGA

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```
1: for  $k = 0, 1, \dots, K - 1$  do  
2:   Сгенерировать независимо  $i_k \sim U(\overline{1, n})$   
3:    $g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k$   
4:    $y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & i = i_k \\ y_i^k, & i \neq i_k \end{cases}$   
5:    $x^{k+1} = x^k - \gamma_k g^k$   
6: end for
```

Выход: x^K

Отметим, что аппроксиматор g^k обладает свойством несмещенности. Действительно, ввиду равномерного и независимого сэмплирования индекса i_k , имеем

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n y_i^k + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).$$

Перейдем к утверждению о сходимости метода SAGA.

Теорема Л14.1. Пусть задача безусловной стохастической оптимизации Л14 суммы с L -гладкими, выпуклыми функциями f_i и μ -сильно выпуклой целевой функцией f решается с помощью SAGA (Алгоритм Л14.1) с $\gamma_k = \gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E} [V_k] \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n} \right) \right\}^k \mathbb{E} [V_0],$$

$$\text{где } V_k = \|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2.$$

Более того, при оптимальном выборе шага для достижения точности ε необходимо

$$\mathcal{O} \left(\left[n + \frac{L}{\mu} \right] \log \frac{1}{\varepsilon} \right) \text{ итераций.}$$

Доказательство. Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k - \nabla f(x^*)\|_2^2.$$

Возьмем условное математическое ожидание по случайности на итерации k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} \left[g^k \mid x^k \right], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k - \nabla f(x^*)\|_2^2 \mid x^k \right]. \end{aligned}$$

Рассмотрим слагаемое $\mathbb{E} [g^k \mid x^k]$:

$$\begin{aligned}\mathbb{E} [g^k \mid x^k] &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k \mid x^k \right] \\ &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k \mid x^k \right] + \frac{1}{n} \sum_{i=1}^n y_i^k \\ &= \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - y_i^k) + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).\end{aligned}$$

Теперь рассмотрим $\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k]$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \right. \right. \\ &\quad \left. \left. + \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 2\mathbb{E} [\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \mid x^k] \\ &\quad + 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Заметим, что если во втором слагаемом взять ξ равным $\nabla f_{i_k}(x^*) - y_{i_k}^k$, то получим дисперсию $\mathbb{E} [\|\xi - \mathbb{E} [\xi \mid x^k]\|_2^2 \mid x^k]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E} [\xi^2]$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 2\mathbb{E} [\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \mid x^k] \\ &\quad + 2\mathbb{E} [\|\nabla f_{i_k}(x^*) - y_{i_k}^k\|_2^2 \mid x^k].\end{aligned}$$

Раскроем математическое ожидание, пользуясь гладкостью и выпуклостью f_i (Теорема Л2.5):

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 4L \cdot \frac{1}{n} \sum_{i=1}^n (f_i(x^k) - f_i(x^*) - \langle \nabla f_i(x^*), x^k - x^* \rangle) \\ &\quad + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \\ &= 4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2.\end{aligned}$$

Собирая все вместе, получаем:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \left(4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью функции f :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - 2\gamma L)(f(x^k) - f^*) \\ &\quad + 2\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2. \end{aligned}$$

Пришли к тому, что если $y_i^k \rightarrow f_i(x^*)$, то есть линейная сходимость. Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] - 2\gamma(1 - 2\gamma L) \mathbb{E} \left[f(x^k) - f^* \right] \\ &\quad + 2\gamma^2 \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \right]. \end{aligned}$$

Теперь рассмотрим, как ведет себя $\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \middle| x^k \right]$:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \middle| x^k \right] &= \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \\ &\quad + \frac{1}{n} \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^*)\|_2^2. \end{aligned}$$

Воспользуемся выпуклостью и гладкостью f_i (Теорема Л2.5):

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \middle| x^k \right] &\leq \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \\ &\quad + \frac{2L}{n} (f(x^k) - f^*). \end{aligned}$$

Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] &\leq \left(1 - \frac{1}{n} \right) \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ &\quad + \frac{2L}{n} \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить». Возьмем $M > 0$ и сложим две рекурренты, которые получились выше:

$$\begin{aligned} &\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + M\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \left(1 + \frac{2}{M} - \frac{1}{n} \right) \mathbb{E} \left[\frac{M\gamma^2}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ &\quad - 2\gamma \left(1 - 2\gamma L - \frac{\gamma ML}{n} \right) \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Возьмем $M = 4n$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq (1 - \mu\gamma) \mathbb{E} [\|x^k - x^*\|_2^2] + \left(1 - \frac{1}{2n}\right) \mathbb{E} \left[4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ & \quad - 2\gamma(1 - 6\gamma L) \mathbb{E} [f(x^k) - f^*]. \end{aligned}$$

Теперь потребуем $\gamma \leq \frac{1}{6L}$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \mathbb{E} \left[\|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right]. \end{aligned}$$

■

Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \rightarrow x^*$, так и $y_i^k \rightarrow \nabla f_i(x^*)$, что и закладывалось в метод.

Замечание Л14.1. Из сходимости по $\mathbb{E}[V_k]$ следует и сходимость по $\mathbb{E}[\|x^k - x^*\|_2^2]$.

Замечание Л14.2. Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M . При этом сходимости лучше, чем $(1 - \frac{1}{n})$, не добиться.

Л14.2 SVRG

В предыдущем разделе мы рассмотрели метод SAGA, который воплощает основную идею редукции дисперсии. Однако, этот метод обладает существенным недостатком — он требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы. В тоже время, классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели. В этом разделе мы рассмотрим метод SVRG, который эффективно по памяти реализует идею редукции дисперсии. Основная идея этого метода заключается в том, чтобы уйти от запоминания стохастических градиентов по каждому индексу i . Вместо восстановления полного градиента с запозданием, как это делает SAGA, SVRG считает полный градиент раз в некоторое время. Такая точка называется *референсной*, а промежуток между подсчетами полного градиента — *эпохой*.

Алгоритм Л14.2 SVRG

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```
1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:   for  $k = 0, 1, \dots, K - 1$  do
4:     Сгенерировать независимо  $i_k \sim U(1, n)$ 
5:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^t) + \nabla f(y^t)$ 
6:      $x^{k+1} = x^k - \gamma_k g^k$ 
7:   end for
8:    $y^{t+1} = x^K$ 
9: end for
Выход:  $y^T$ 
```

Аппроксиматор в SVRG несмещенный:

$$\mathbb{E}[g^k | x^k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

Аналогично SAGA можно показать, что из того что $y^k \rightarrow x^*$, следует, что $g^k \rightarrow 0$. Итерационная сложность сходимости метода — $\mathcal{O}\left(n + \frac{L}{\mu}\right) \log \frac{1}{\varepsilon}$ совпадает с SAGA. Однако, необходимость вычислять полный градиент даже раз в эпоху, а также два стохастических градиента на каждой итерации требует дополнительных вычислительных мощностей.

Л14.3 SARAH

В предыдущем разделе мы рассмотрели метод редукции дисперсии SVRG, эффективный по памяти. При этом, SVRG не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода. Решая квадратичную задачу минимизации всего лишь с $d = 2$, $n = 5$, мы наблюдаем траекторию, как на Рисунке Л14.1.




Рис. Л14.1: Сравнение методов SVRG и SARAH на квадратичной функции.

По этой причине, был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках. Он использует идею рекурсивного накопления градиентов. Такая схема на каждой итерации добавляет к аппроксиматору направление градиента в новой точке, при этом вычитая старое направление. В то время как полный градиент в референсной точке из SVRG мешает сходиться к решению, добавляя вклад старого направления в текущий шаг, SARAH динамично подставляет траекторию под правильное направление к минимуму (Рисунок Л14.1).

Алгоритм Л14.3 SARAH

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```

1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:    $g^{-1} = \nabla f(x^0)$ 
4:   for  $k = 0, 1, \dots, K - 1$  do
5:     Сгенерировать независимо  $i_k \sim U(\overline{1}, n)$ 
6:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}$ 
7:      $x^{k+1} = x^k - \gamma_k g^k$ 
8:   end for
9:    $y^{t+1} = x^K$ 
10: end for
Выход:  $y^K$ 

```

Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ. Однако SARAH все еще сохраняет идею редукции дисперсии: при $x^k \rightarrow x^*$ имеем, что $g^k \rightarrow 0$. SARAH, аналогично SVRG имеет итерационную сложность $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$, а также требует периодического вычисления полного градиента и подсчета двух стохастических градиентов на каждой итерации. Тем не менее, SARAH решает проблему с нестабильной траекторией сходимости.

Л14.4 Loopless версии алгоритмов

Отличительной чертой разобранных выше методов SVRG и SARAH является структура, состоящая из двух циклов. Такое построение алгоритма обладает двумя недостатками:

1. Фиксированная длина эпохи в классическом анализе SVRG имеет порядок $\frac{L}{\mu}$, что делает эпоху очень большой ввиду маленьких значений μ на практике;
2. При естественной длине эпохи порядка n метод не достигает скорости сходимости $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$.

По этим причинам были предложены методы редукции дисперсии, которые не используют фиксированную длину эпохи, а значит ограничиваются структурой с одним циклом. Такие модификации называются *loopless* версиями, и как правило используют случайность для решения сделать шаг по аппроксиматору или по полному градиенту:

$$x^{k+1} = x^k - \gamma_k \begin{cases} g^k, & \text{с вероятностью } p \\ \nabla f(x^k), & \text{с вероятностью } 1 - p \end{cases}.$$

Алгоритм Л14.4 L-SVRG (Loopless SVRG)

Вход: стартовая точка $x^0 = y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, вероятность обновления $p \in (0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
- 3: $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k) + \nabla f(y^k)$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: $y^{k+1} = \begin{cases} x^k, & \text{с вероятностью } p \\ y^k, & \text{с вероятностью } 1 - p \end{cases}$
- 6: **end for**

Выход: x^K

Алгоритм Л14.5 PAGE (Loopless SARAH)

Вход: стартовая точка $x^{-1} = x^0 \in \mathbb{R}^d$, стартовый аппроксиматор $g^{-1} = \nabla f(x^{-1})$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, вероятность обновления $p \in (0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
- 3: $g^k = \begin{cases} \nabla f(x^k), & \text{с вероятностью } p \\ \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}, & \text{с вероятностью } 1 - p \end{cases}$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Выход: x^T

Итерационная сложность алгоритмов равна $\mathcal{O}\left(\frac{1}{p} + n + \frac{L}{\mu} + \frac{Lpn}{\mu}\right)$. Таким образом можно выбрать вероятность подсчета полного градиента $p = \frac{1}{n}$, естественным образом связав ее с количеством функций из постановки, а не с числом обусловленности задачи. При этом, сложность сходимости остается $\mathcal{O}\left(n + \frac{L}{\mu}\right)$, как и в базовых версиях алгоритмов.

Л14.5 Унифицированный анализ методов редукции дисперсии

Ранее были изучены отдельные методы редукции дисперсии и их особенности. Однако все эти подходы можно рассматривать как частные случаи единого более общего метода. Такой взгляд позволяет описывать и анализировать различные стохастические алгоритмы редукции дисперсии в рамках одной унифицированной модели. Ниже мы сформулируем ключевое предположение, на котором основан этот подход. Схема обновления стохастических методов может быть обобщена следующим образом:

Алгоритм Л14.6 Общая схема стохастического градиентного спуска

Вход: начальная точка x^0 , число итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать стохастическую переменную ξ^k
- 3: Вычислить стохастическую оценку градиента: $g^k = g^k(x^k, \xi^k, \text{history})$
- 4: Обновить точку: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Предположение Л14.1. Пусть $\{x^t\}$ — последовательность итераций Алгоритма Л14.6, а $\{\xi_t\}$ — случайные величины, порождаемые им. Предположим, что существуют неотрицательные константы A, B, C и параметры $\rho_1, \rho_2 \in (0, 1]$, а также (возможно случайная) последовательность $\{\sigma_t^2\}$, такие что для всех k выполняются неравенства:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &\leq (1 - \rho_1) \|g^{k-1} - \nabla f(x^{k-1})\|_2^2 + A\sigma_{k-1}^2 \\ &\quad + BL^2 \|x^k - x^{k-1}\|_2^2, \\ \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq (1 - \rho_2) \sigma_{k-1}^2 + CL^2 \|x^k - x^{k-1}\|_2^2. \end{aligned}$$

Это предположение описывает, как ведёт себя ошибка стохастического аппроксиматора градиента при последовательных итерациях алгоритма. Параметры ρ_1 и ρ_2 определяют степень сжатия ошибок: чем они больше, тем быстрее различие между стохастической оценкой и истинным градиентом уменьшается при приближении к оптимуму. Константы A, B и C контролируют влияние стохастичности и длины шага на поведение метода. Таким образом, предположение Л14.1 задаёт общую схему, в рамках которой можно описывать как простейший стохастический градиентный спуск, так и более сложные методы с редукцией дисперсии, включая SAGA, SVRG, SARAH. Важно, что данное предположение не требует, чтобы g^k являлся несмещённой оценкой градиента. Кроме того, оно не предполагает использования больших батчей или строгих свойств задачи, что повышает общность получаемых результатов. После введения основного предположения, описывающего поведение стохастической ошибки градиентного оценщика, мы можем перейти к выводам, характеризующим сходимость рассматриваемых алгоритмов. Чтобы обосновать сделанные предположения, начнём с анализа невыпуклой и RL-задачи (условие Поляка–Лоясиевича).

Определение Л14.1. Непрерывно дифференцируемая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ удовлетворяет условию Поляка–Лоясиевича с константой $\mu > 0$, если для всех $x \in \mathbb{R}^d$ выполнено

$$f(x) - f^* \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2.$$

В невыпуклом случае любой метод, описываемый Алгоритмом Л14.6, обладает сублинейной скоростью сходимости.

Утверждение Л14.1 (Лемма 2 из [18]). Пусть задача безусловной стохастической оптимизации Л14 суммы с L -гладкой целевой функцией f решается с помощью Алгоритма Л14.1. Тогда справедлива следующая оценка сходимости

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \frac{\gamma_k}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma_k} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma_k}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Теорема Л14.2. Пусть задача безусловной стохастической оптимизации Л14 с L -гладкой целевой функцией f решается с помощью Алгоритма Л14.6 с

$$\gamma_k = \gamma \leq \frac{1}{L} \left(1 + \sqrt{\frac{B\rho_2 + AC}{\rho_1\rho_2}} \right)^{-1}$$

в Предположении Л14.6. Тогда справедлива следующая оценка сходимости:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \right] \leq \frac{2V^0}{\gamma K},$$

где $V_0 = f(x^0) - f^* + \frac{\gamma}{2\rho_1} \|g^0 - \nabla f(x^0)\|_2^2 + \frac{\gamma A}{2\rho_1 \rho_2} \sigma_0^2$.

Доказательство. Запишем результат Утверждения Л14.1:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Добавим $\frac{\gamma}{2\rho_1} \|g^{k+1} - \nabla f(x^{k+1})\|_2^2$, $\frac{\gamma A}{2\rho_1 \rho_2} \sigma_{k+1}^2$ к обоим частям и возьмем условное математическое ожидание:

$$\begin{aligned} \mathbb{E} [V_{k+1} \mid x^{k+1}] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{2\rho_1} \mathbb{E} \left[\|g^{k+1} - \nabla f(x^{k+1})\|_2^2 \mid x^{k+1} \right] + \frac{\gamma A}{2\rho_1 \rho_2} \mathbb{E} [\sigma_{k+1}^2 \mid x^{k+1}]. \end{aligned}$$

Воспользуемся Предположением Л14.6:

$$\begin{aligned} \mathbb{E} [V_{k+1} \mid x^{k+1}] &\leq f(x^k) - f^* + \frac{\gamma}{2\rho_1} \|g^k - \nabla f(x^k)\|_2^2 + \frac{\gamma A}{2\rho_1 \rho_2} \sigma_k^2 - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + \gamma^2 L^2 \frac{B\rho_2 + AC}{\rho_1 \rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Учтем, что $\gamma^2 L^2 \frac{B\rho_2 + AC}{\rho_1 \rho_2} + \gamma L \leq 1$ и возьмем полное математическое ожидание:

$$\mathbb{E} [V_{k+1}] \leq \mathbb{E} [V_k] - \frac{\gamma}{2} \mathbb{E} [\|\nabla f(x^k)\|_2^2],$$

откуда получаем, что

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [\|\nabla f(x^k)\|_2^2] \leq \frac{2V^0}{\gamma K}.$$

■

Таким образом, даже без дополнительных условий на выпуклость функции, алгоритм демонстрирует уменьшение нормы градиента в среднем со скоростью $\mathcal{O}(\frac{1}{K})$, что соответствует классическому сублинейному поведению стохастических методов. Далее приведем теорему сходимости для функции, удовлетворяющей условию Поляка–Лоясиевича.

Теорема Л14.3. Пусть задача безусловной стохастической оптимизации Л14 с L -гладкой целевой функцией f , удовлетворяющей условию Поляка–Лоясиевича,

решается с помощью Алгоритма Л14.6 с

$$\gamma_k = \gamma \leq \min \left\{ \frac{1}{L} \left(1 + \sqrt{\frac{B\rho_2 + 2AC}{\rho_1\rho_2}} \right)^{-1}, \frac{\min\{\rho_1, \rho_2\}}{2\mu} \right\}$$

в Предположении Л14.6. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E}[V_K] \leq (1 - \gamma\mu)^K V_0,$$

где $V_k = f(x^k) - f^* + \frac{\gamma}{\rho_1} \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \sigma_k^2$.

Доказательство. Запишем результат Утверждения Л14.1:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Добавим $\frac{\gamma}{\rho_1} \|g^{k+1} - \nabla f(x^{k+1})\|_2^2$, $\frac{2\gamma A}{\rho_1\rho_2} \sigma_{k+1}^2$ к обоим частям и возьмем условное математическое ожидание:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^k] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{\rho_1} \mathbb{E}[\|g^{k+1} - \nabla f(x^{k+1})\|_2^2 | x^{k+1}] + \frac{2\gamma A}{\rho_1\rho_2} \mathbb{E}[\sigma_{k+1}^2 | x^{k+1}]. \end{aligned}$$

Воспользуемся Предположением Л14.6:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^{k+1}] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + 2\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Воспользуемся условием Поляка–Лоясиевича:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^{k+1}] &\leq (1 - \gamma\mu)(f(x^k) - f^*) \\ &\quad + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + 2\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Учтем, что $\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} + \gamma L \leq 1$ и возьмем полное математическое ожидание:

$$\mathbb{E}[V_{k+1}] \leq (1 - \gamma\mu)(f(x^k) - f^*) + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2,$$

Следовательно, если $\gamma \leq \frac{\min\{\rho_1, \rho_2\}}{2\mu}$, то

$$V_{k+1} \leq (1 - \gamma\mu)V_k \leq (1 - \gamma\mu)^{k+1} V_0.$$

■

Этот результат показывает, что при выполнении условия Поляка–Лоясиевича и разумном выборе шага γ методы редукции дисперсии достигают экспоненциального уменьшения функционального разрыва, объединяя тем самым свойства как стохастического градиентного спуска, так и его ускоренных вариантов. Далее докажем, что обобщаемые выше методы удовлетворяют Предположению Л14.1. Будем рассматривать батчированные версии и для начала остановимся на вспомогательном утверждении.

Утверждение Л14.2 (Лемма А.1 из [16]). Пусть $x_1, \dots, x_n \in \mathbb{R}^d$ — произвольные вектора с нулевой суммой:

$$\sum_{i=1}^n x_i = 0$$

и S размера b из $U(\overline{1, n})$. Тогда

$$\mathbb{E} \left[\left\| \frac{1}{b} \sum_{i \in S} x_i \right\|_2^2 \right] \leq \frac{1}{bn} \sum_{i=1}^n \|x_i\|_2^2.$$

Л14.5.1 SAGA

Сформулируем теорему, устанавливающую параметры Предположения Л14.1 для SAGA.

Теорема Л14.4. SAGA (Алгоритм Л14.1) удовлетворяет предположению Л14.1 с:

$$A = \frac{1}{b} \left(1 + \frac{b}{2n} \right), \quad B = \frac{1}{b} \left(1 + \frac{2n}{b} \right), \quad C = \frac{2n}{b},$$

$$\rho_1 = 1, \quad \rho_2 = \frac{b}{2n},$$

$$\sigma_k^2 = \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^{k+1}\|_2^2.$$

Доказательство. Ограничим разницу между аппроксиматором градиента и реальным градиентом:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} (\nabla f_{i_k}(x^k) - y_{i_k}^k) + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^k) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} \left(\nabla f_{i_k}(x^k) - y_{i_k}^k - \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - y_i^k) \right) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л14.2:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \left\| \nabla f_i(x^k) - y_i^k - \left(\frac{1}{n} \sum_{j=1}^n (\nabla f_j(x^k) - y_j^k) \right) \right\|_2^2$$

Если взять ξ равным $\nabla f_i(x^k) - y_i^k$, то получим дисперсию $\mathbb{E} \left[\|\xi - \mathbb{E}[\xi]\|_2^2 \right]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^k\|_2^2$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &\leq \frac{1}{bn} \left(1 + \frac{2n}{b} \right) \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^{k-1})\|_2^2 \\ &\quad + \frac{1}{bn} \left(1 + \frac{b}{2n} \right) \sum_{i=1}^n \|\nabla f_i(x^{k-1}) - y_i^k\|_2^2. \end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{b} \left(1 + \frac{b}{2n} \right) \sigma_{k-1}^2 + \frac{1}{b} \left(1 + \frac{2n}{b} \right) \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

Теперь посмотрим на σ_k^2 :

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^{k+1}\|_2^2 \mid x^k \right] = \left(1 - \frac{b}{n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^k\|_2^2 \\ &= \left(1 - \frac{b}{n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^{k-1}) + \nabla f_i(x^{k-1}) - y_i^{k-1}\|_2^2. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq \left(1 - \frac{b}{n} \right) \left(1 + \frac{b}{2n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^{k-1}) - y_i^{k-1}\|_2^2 \\ &\quad + \left(1 - \frac{b}{n} \right) \left(1 + \frac{2n}{b} \right) \|\nabla f_i(x^k) - \nabla f_i(x^{k-1})\|_2^2. \end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\sigma_k^2 \mid x^k \right] \leq \left(1 - \frac{b}{2n} \right) \sigma_{k-1}^2 + \frac{2n}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л14.5.2 L-SVRG

Сформулируем теорему, показывающую соответствие L-SVRG унифицированной схеме анализа.

Теорема Л14.5. L-SVRG (Алгоритм Л14.4) удовлетворяет Предположе-

нию Л14.1 с:

$$\begin{aligned} A &= \frac{2}{b}, \quad B = \frac{2}{b}, \quad C = 1 + \frac{2}{p}, \\ \rho_1 &= 1, \quad \rho_2 = \frac{p}{2}, \\ \sigma_k^2 &= \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^{k+1}) - \nabla f_i(x^k)\|_2^2. \end{aligned}$$

Доказательство. Ограничим разницу между аппроксиматором градиента и реальным градиентом:

$$\begin{aligned} &\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} (\nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k)) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^k) - \nabla f(x^k) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} \left(\nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k) - \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - \nabla f_i(y^k)) \right) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л14.2:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(y^k) - \left(\frac{1}{n} \sum_{j=1}^n (\nabla f_j(x^k) - \nabla f_j(y^k)) \right) \right\|_2^2$$

Если взять ξ равным $\nabla f_i(x^k) - \nabla f_i(y^k)$, то получим дисперсию $\mathbb{E} \left[\|\xi - \mathbb{E}[\xi]\|_2^2 \right]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(y^k)\|_2^2.$$

Продолжим преобразования:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{2}{bn} \sum_{i=1}^n \|\nabla f_i(y^k) - \nabla f_i(x^{k-1})\|_2^2 + \frac{2}{bn} \sum_{i=1}^n \|f_i(x^k) - f_i(x^{k-1})\|_2^2.$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{2}{b} \sigma_{k-1}^2 + \frac{2}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

Теперь посмотрим на σ_k^2 :

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^{k+1}) - \nabla f_i(x^k)\|_2^2 \mid x^k \right] \\ &= (1-p) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^k) - \nabla f_i(x^k)\|_2^2. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned}
\mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq (1-p) \left(1 + \frac{p}{2} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(y^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\quad + (1-p) \left(1 + \frac{2}{p} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\leq \left(1 - \frac{p}{2} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(y^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\quad + \left(1 + \frac{2}{p} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^{k-1}) \right\|_2^2.
\end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\sigma_k^2 \mid x^k \right] \leq \left(1 - \frac{p}{2} \right) \sigma_{k-1}^2 + \left(1 + \frac{2}{p} \right) \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л14.5.3 PAGE

Сформулируем теорему для PAGE. Примечательно, что в отличие от SAGA и L-SVRG, здесь $\sigma_k^2 = 0$, что радикально упрощает потенциальную функцию и структуру доказательства сходимости.

Теорема Л14.6. PAGE (Алгоритм Л14.5) удовлетворяет Предположению Л14.1 с:

$$\begin{aligned}
A &= 0, \quad B = \frac{1-p}{b}, \quad C = 0, \\
\rho_1 &= p, \quad \rho_2 = 1, \\
\sigma_k^2 &= 0.
\end{aligned}$$

Доказательство. Воспользуемся Леммой 3 из [18]:

$$\mathbb{E} \left[\left\| \nabla f(x^k) - g^k \right\|_2^2 \mid x^k \right] \leq (1-p) \left\| \nabla f(x^{k-1}) - g^{k-1} \right\|_2^2 + \frac{1-p}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■