

Л15 Методы нулевого порядка и координатный спуск

В этом параграфе рассматриваются методы, направленные на снижение вычислительной стоимости одной итерации градиентного спуска. Сначала обсуждаются координатные методы, далее показывается, что та же идея может быть использована, когда градиент недоступен (zero-order оптимизация). Рассмотрим задачу безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x). \quad (\text{Л15.1})$$

Л15.1 Координатный спуск

Координатные методы — это алгоритмы оптимизации, где на каждой итерации обновляется лишь одна (или несколько) координат вектора параметров, при этом остальные фиксируются. Приведем мотивационный пример с линейной регрессией.

Пример Л15.1. Рассмотрим квадратичную задачу

$$\min_{x \in \mathbb{R}^d} f(x) := \frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} \sum_{i=1}^n (A_{i,:}x - b_i)^2 = \frac{1}{2} \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle x_j - \frac{1}{2} \langle b, Ax - b \rangle.$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i -ая строка матрицы A , $A_{:,j}$ — j -ый столбец матрицы A , $b \in \mathbb{R}^n$ — метки. Полный градиент в этой задаче имеет вид

$$\nabla f(x) = A^\top (Ax - b) = \sum_{i=1}^n A_{i,:}^\top (A_{i,:}x - b_i) = \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle e_j, \quad (\text{Л15.2})$$

где e_j — j -ый базисный вектор. Рассмотрим два классических подхода к удешевлению стоимости одной итерации вычисления градиентного шага.

1. Стохастический выбор строки (стохастический градиентный спуск по объектам).

На итерации k равномерно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы (Л15.2):

$$g^k = n A_{i_k,:}^\top (A_{i_k,:}x^k - b_{i_k}), \\ x^{k+1} = x^k - \gamma_k g^k.$$

Этот шаг использует только одну строку матрицы A , множитель n нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$. Стоимость одной итерации в n раз дешевле, чем полный градиент, так как выбирается 1 объект из суммы с n слагаемыми.

2. Стохастический выбор столбца (координатный шаг).

На итерации k равномерно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора (Л15.2):

$$g^k = d \langle Ax^k - b, A_{:,j_k} \rangle e_{j_k}, \\ x^{k+1} = x^k - \gamma_k g^k.$$

Этот шаг использует только один столбец матрицы A . Множитель d нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$. Стоимость одной итерации в d раз дешевле, чем полный градиент, так как делается 1 скалярное произведение вместо d .

Таким образом в квадратичной задаче две симметричные экономии достигаются выбором строк или столбцов, что соответствует домножению каждую итерацию на одну случайную строку или столбец матрицы A соответственно.

В этом параграфе мы сосредоточимся на втором подходе, со стохастическими методами можно ознакомиться в Параграфах Л15 и Л14. Перейдём к формальному описанию алгоритма координатного спуска, в котором вместо полного градиента оценивается и используется одна его координата.

Алгоритм Л15.1 Координатный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
 - 3: $x^{k+1} = x^k - \gamma_k d[\nabla f(x^k)]_{i_k} e_{i_k}$
 - 4: **end for**
- Выход:** x^K
-

Заметим, что при равномерном выборе координаты стохастический градиент обладает двумя ключевыми свойствами — он остаётся несмещённой оценкой полного градиента и имеет контролируруемую дисперсию.

Утверждение Л15.1. Пусть индекс $i_k = \overline{1, d}$ выбирается независимо и равномерно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняются равенства:

$$\mathbb{E} [d[\nabla f(x)]_{i_k} e_{i_k}] = \nabla f(x), \quad \mathbb{E} [\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2] = d \|\nabla f(x)\|_2^2.$$

Доказательство. Покажем первое равенство:

$$\mathbb{E} [d[\nabla f(x)]_{i_k} e_{i_k}] = \sum_{i=1}^d \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Покажем второе равенство:

$$\mathbb{E} [\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2] = \sum_{i=1}^d \frac{1}{d} d^2 [\nabla f(x)]_i^2 \|e_i\|_2^2 = d \|\nabla f(x)\|_2^2.$$

■

Утверждение Л15.1 показывает, что стохастическая координатная оценка градиента $d[\nabla f(x)]_{i_k} e_{i_k}$ несмещена, однако её разброс не является константой: дисперсия масштабируется величиной $\|\nabla f(x)\|_2^2$. Интуитивная причина проста: мы наблюдаем только одну координату из d и затем восстанавливаем масштаб умножением на d . Опираясь на Утверждение Л15.1, которое гарантирует несмещённость и контролируемую дисперсию стохастической оценки градиента, зафиксируем величину шага и выведем оценку скорости сходимости алгоритма Л15.1.

Теорема Л15.1. Пусть задача безусловной оптимизации (Л15.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью координатного спуска

ка (Алгоритм Л15.1). Тогда при $\gamma_k = \gamma \leq \frac{1}{dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

Доказательство. По определению итерации:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle d[\nabla f(x^k)]_{i_k} e_{i_k}, x^k - x^* \rangle + \gamma^2 \|d[\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} \left[d[\nabla f(x^k)]_{i_k} e_{i_k} \mid x^k \right], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|d[\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2 \mid x^k \right]. \end{aligned}$$

Применим Утверждение Л15.1:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \|\nabla f(x^k)\|_2^2.$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - d\gamma L)(f(x^k) - f^*).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое отрицательно, и остаётся

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2.$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

■

Одна координатная итерация примерно в d раз дешевле шага полного градиентного спуска, но обычно требуется порядка в d раз больше итераций. В чистом виде это не улучшает асимптотику, однако на практике координатные методы часто выигрывают по времени до заданной точности за счёт разреженности данных и дешёвых локальных операций по столбцам, неравномерного выбора координат с вероятностями, пропорциональными координатным константам Липшица, а также блочно-координатных, параллельных и асинхронных обновлений, эффективно использующих современную вычислительную архитектуру. В неквадратичных задачах вычислить одну координату градиента не всегда дешевле, чем полный градиент. Чтобы получить $[\nabla f(x)]_i$, нередко требуется выполнить почти всю вычислительную цепочку и лишь затем извлечь i -ую компоненту. Поэтому координатный шаг не всегда экономит ресурсы. Характерный неблагоприятный пример — логистическая регрессия: градиент есть сумма по всем объектам, и для любой координаты нужен полный проход по данным. Фактически стоимость одной координаты совпадает со стоимостью полного градиента. В то же время при обучении нейронных сетей ситуация благоприятнее из-за структуры обратного распространения ошибки: градиенты считаются от последнего слоя к первому, и, если обновлять только слой i , можно не вычислять градиенты для слоёв $1, \dots, i-1$. Это уменьшает объём обратных вычислений и снижает пиковые требования к памяти, что даёт реальное ускорение и экономию ресурсов при координатных или

блочно-координатных обновлениях по слоям. Когда прямой градиент недоступен или слишком дорог, координатная логика получает «вторую жизнь», переходя к оценкам направленных производных по случайным направлениям, мы естественно приходим к методам нулевого порядка (ZO), где двухточечные разности выступают оценками градиента.

Л15.2 Координатные идеи в безградиентной постановке

В оптимизации нулевого порядка алгоритм взаимодействует с целевой функцией через её значение. Отсутствие доступа к градиенту вынуждает заменять его на аппроксимацию по значениям функции, что естественным образом сочетается с координатными идеями — можно оценивать лишь нужные координатные направления и выполнять дешёвые обновления. Ключевой приём — аппроксимация направленной производной по значениям функции вдоль направления $e \in \mathbb{R}^d$. Рассмотрим три стандартные схемы.

$$g(x, e) = \begin{cases} d \frac{f(x+\tau e) - f(x-\tau e)}{2\tau} e & \text{(двухточечная симметричная)} \\ \frac{f(x+\tau e) - f(x)}{\tau} e & \text{(двухточечная односторонняя)} \\ \frac{f(x+\tau e)}{\tau} e & \text{(одноточечная),} \end{cases} \quad (\text{Л15.3})$$

где $\tau > 0$ — параметр сглаживания. Двухточечная симметричная схема имеет наименьшее смещение. Двухточечная Односторонняя схема используется, когда $f(x)$ уже было посчитано. Одноточечная схема наиболее дешёвая по вычислениям, но обладает большим смещением. Множитель d в (Л15.3) появляется по той же причине, что и в координатных методах: усреднение по случайно выбранному направлению «размывает» вклад по d осям, и чтобы восстановить исходный масштаб градиента, требуется умножение на d . Перейдём к самой интересной части формулы (Л15.3) — выбору направления e , по которому мы будем оптимизировать целевую функцию. Координатный базис $e = e_i$ воспроизводит по координатный шаг, но охватывает лишь одну компоненту за вызов оракула. Лучше сразу смотреть на все координаты через случайные направления. Самый простой вариант — брать $e \sim \mathcal{N}(0, I_d)$ — такая выборка случайно смешивает все координаты в каждом направлении и в среднем захватывает всю структуру. Ещё лучше выбирать e равномерно на сфере $S^{d-1} := \{e \in \mathbb{R}^d \mid \|e\|_2 = 1\}$: все направления имеют одинаковую норму, что стабилизирует шаги и улучшает оценки, при этом мы так же охватываем все координаты.

У читателя мог возникнуть вопрос: почему в (Л15.3) не устремить $\tau \rightarrow 0$ и не получить градиент по определению? В оптимизации нулевого порядка это невозможно из-за доминирующей роли ошибок оракула: на запрос точки возвращается не истинное значение, а зашумлённая величина $\hat{f}$. В оптимизации первого порядка шум также присутствует, однако его влияние обычно существенно слабее, поскольку градиент сглаживает часть вариативности. Исходя из этих соображений, в формуле (Л15.3) следует везде заменить f на $\hat{f}$. Для двухточечной симметричной оценки:

$$g(x, e) = d \frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e.$$

Л15.2.1 Гладкий μ -сильно выпуклый случай

Подобно координатной оценке первого порядка, двухточечная схема $g(x, e)$ служит стохастической заменой градиента. Ниже формализуем её несмещённость, характер погрешности, а также оценку второго момента.

Утверждение Л15.2. Пусть дана L -гладкая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и пусть

$\hat{f}(x) = f(x) + \xi(x)$, где $|\xi(x)| \leq \Delta$ для всех $x \in \mathbb{R}^d$. Определим оценку градиента

$$g(x, e) = d \frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e, \quad e \sim U(S^{d-1}).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливы оценки:

1. $\|\mathbb{E}_{e \sim U(S^{d-1})}[g(x, e)] - \nabla f(x)\|_2 \leq L\tau + \frac{d\Delta}{\tau},$
2. $\mathbb{E}_{e \sim U(S^{d-1})}\|g(x, e)\|_2^2 = 4d\|\nabla f(x)\|_2^2 + 4L^2d^2\tau^2 + 2\frac{d^2\Delta^2}{\tau^2}.$

Доказательство. Разложим оценку на две части $g(x, e) = g^{\det} + g^{\text{noise}}$:

$$g^{\det} = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad g^{\text{noise}} = d \frac{\xi(x + \tau e) - \xi(x - \tau e)}{2\tau} e.$$

1. Для шумовой составляющей имеем:

$$\left\| \mathbb{E} \left[g^{\text{noise}} \right] \right\|_2 = \frac{d}{2\tau} \left\| \mathbb{E} [(\xi(x + \tau e) - \xi(x - \tau e))e] \right\|_2 \leq \frac{d}{2\tau} \cdot 2\Delta \cdot \mathbb{E} [\|e\|_2] = \frac{d\Delta}{\tau}.$$

Рассмотрим детерминированную часть, представим симметричную разность в форме интеграла:

$$g^{\det} = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e = de \int_{-1}^1 \frac{1}{2} \langle \nabla f(x + t\tau e), e \rangle dt.$$

Перейдём к математическому ожиданию по равномерному e , воспользуемся тем, что $\mathbb{E} [ee^\top] = \frac{1}{d} I_d$:

$$\mathbb{E} [g^{\det}] = d\mathbb{E} \left[\frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e \right] = \mathbb{E} [\nabla f(x + t\tau e)].$$

Тогда имеем:

$$\begin{aligned} \left\| \mathbb{E} [g^{\det}] - \nabla f(x) \right\|_2 &= \left\| \mathbb{E} [\nabla f(x + t\tau e)] - \mathbb{E} [\nabla f(x)] \right\|_2 \\ &= \left\| \mathbb{E} [\nabla f(x + t\tau e) - \nabla f(x)] \right\|_2 \\ &\leq \mathbb{E} [\|\nabla f(x + t\tau e) - \nabla f(x)\|_2] \\ &\leq L\tau \|e\|_2 = L\tau. \end{aligned}$$

Воспользуемся неравенством треугольника:

$$\|\mathbb{E} [g(x, e)] - \nabla f(x)\|_2 \leq \left\| \mathbb{E} [g^{\det}] - \nabla f(x) \right\|_2 + \left\| \mathbb{E} [g^{\text{noise}}] \right\|_2 \leq L\tau + \frac{d\Delta}{\tau}.$$

2. Для шумовой составляющей имеем:

$$\mathbb{E} [\|g^{\text{noise}}\|_2^2] = \frac{d^2}{4\tau^2} \mathbb{E} [\|(\xi(x + \tau e) - \xi(x - \tau e))e\|_2^2] \leq \frac{d^2}{4\tau^2} \cdot 4\Delta^2 \cdot \mathbb{E} [\|e\|_2^2] = \frac{d^2\Delta^2}{\tau^2}.$$

Посмотрим на детерминированную часть, добавим умный ноль $\pm \langle \nabla f(x), e \rangle e$:

$$\mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] = d^2 \mathbb{E} \left[\left\| \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e + \langle \nabla f(x), e \rangle e - \langle \nabla f(x), e \rangle e \right\|_2^2 \right].$$

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned} \mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] &\leq 2d^2 \mathbb{E} \left[|\langle \nabla f(x), e \rangle|^2 \right] \\ &\quad + \frac{d^2}{2\tau^2} \mathbb{E} \left[|f(x + \tau e) - f(x - \tau e) - \langle \nabla f(x), 2\tau e \rangle|^2 \right]. \end{aligned}$$

Воспользуемся изотропией равномерного направления на сфере и Теоремой Л2.4:

$$\mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] \leq 2d \|\nabla f(x)\|_2^2 + 2L^2 d^2 \tau^2.$$

Получим итоговую оценку:

$$\begin{aligned} \mathbb{E} \left[\|g(x, e)\|_2^2 \right] &= \mathbb{E} \left[\|g^{\text{det}} + g^{\text{noise}}\|_2^2 \right] \leq 2\mathbb{E} \left[\|g^{\text{det}}\|_2^2 \right] + 2\mathbb{E} \left[\|g^{\text{noise}}\|_2^2 \right] \\ &\leq 4d \|\nabla f(x)\|_2^2 + 4L^2 d^2 \tau^2 + 2 \frac{d^2 \Delta^2}{\tau^2}. \end{aligned}$$

■

Используя двухточечную оценку градиента из Утверждения Л15.2, построим базовый стохастический метод нулевого порядка.

Алгоритм Л15.2 ZO-GD с двухточечной оценкой

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметр сглаживания $\tau > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $e_k \sim U(S^{d-1})$
- 3: $g^k = d \frac{\hat{f}(x^k + \tau e_k) - \hat{f}(x^k - \tau e_k)}{2\tau} e_k$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Выход: x^K

Утверждение Л15.2 даёт контролируемую оценку второго момента, в которой естественным образом появляются параметр сглаживания τ и уровень шумовой погрешности оракула Δ . Это позволяет сформулировать и проанализировать базовый алгоритм нулевого порядка.

Теорема Л15.2. Пусть задача безусловной оптимизации (Л15.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л15.2). Тогда при $\gamma_k = \gamma \leq \frac{1}{8dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq \left(1 - \frac{\mu\gamma}{2}\right)^k \|x^0 - x^*\|_2^2 + \frac{4}{\mu} \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \mathbb{E} [g^k \mid x^k], x^k - x^* \rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right] \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + 2\gamma \langle \nabla f(x^k) - \mathbb{E} [g^k \mid x^k], x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma}{\mu} \left\| \mathbb{E} [g^k \mid x^k] - \nabla f(x^k) \right\|_2^2 + \frac{\mu\gamma}{2} \|x^k - x^*\|_2^2 \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л15.2:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \left(1 + \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma}{\mu} \left(L^2 \tau^2 + \frac{d^2 \Delta^2}{\tau^2} \right) \\ &\quad + \gamma^2 \left(4d \|\nabla f(x^k)\|_2^2 + 4L^2 d^2 \tau^2 + 2 \frac{d^2 \Delta^2}{\tau^2} \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \left(1 - \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 - 2\gamma (1 - 4d\gamma L) (f(x^k) - f^*) \\ &\quad + 2\gamma \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{d^2 \Delta^2}{\tau^2} \left(\gamma + \frac{1}{\mu} \right) \right). \end{aligned}$$

Выбирая $\gamma \leq \frac{1}{8dL}$, получаем:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \left(1 - \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 + 2\gamma \left(2L^2 \tau^2 \left(\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq \left(1 - \frac{\mu\gamma}{2} \right)^k \|x^0 - x^*\|_2^2 + \frac{4}{\mu} \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

■

Появление τ отражает баланс смещения/дисперсии: уменьшение τ снижает смещение, но повышает вариативность из-за деления на τ в двухточечной формуле. Наоборот, увеличение τ уменьшает дисперсию, но усиливает сглаживающее смещение. В отсутствие шума оптимальной оказывается $\tau = 0$, при наличии шума целесообразно фиксировать τ близкой к балансу $\tau^* \sim \sqrt{\Delta d/L}$.

Л15.2.2 Негладкий выпуклый случай

В отличие от рассмотренного ранее гладкого μ -сильно выпуклого случая, теперь мы не предполагаем L -Липшицевость, а работаем с M -Липшицевой выпуклой функцией:

$$|f(x) - f(y)| \leq M\|x - y\|_2.$$

Дополнительно мы полагаем отсутствие шума оракула значений, то есть $\Delta = 0$, чтобы не перегружать изложение сложными балансами смещения/дисперсии и сосредоточиться на ключевой идее сферического сглаживания и базовой конвергенции ZO-методов. Случай $\Delta > 0$ приводит лишь к стандартной шумовой добавке в итоговых оценках и разбирается аналогично. В этом разделе ключевым понятием является сферически сглаженная функция f_τ , которая позволит нам перенести технику анализа методов первого порядка в настройках нулевого порядка.

Определение Л15.1. Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — выпуклая функция. Будем называть *сглаженной функцией*, функцию

$$f_\tau(x) = \mathbb{E}_{e \sim U(S^{d-1})}[f(x + \tau e)].$$

Формально, Определение Л15.1 представляет собой сферическое усреднение значения f по равномерному направлению на сфере радиуса τ , в результате чего f_τ становится дифференцируемой, а её градиент естественным образом согласуется с двухточечной ZO-оценкой. Формальные свойства функции $f_\tau(x)$ изложены в следующем утверждении.

Утверждение Л15.3. Для M -Липшицевой выпуклой функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$ выполняется:

1. f_τ дифференцируема и

$$\nabla f_\tau(x) = \mathbb{E}_{e \sim U(S^{d-1})} \left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e \right];$$

2. f_τ выпукла и

$$0 \leq f_\tau(x) - f(x) \leq \tau M;$$

3. Градиент $f_\tau(x)$ ограничен:

$$\|\nabla f_\tau(x)\|_2 \leq dM.$$

Доказательство.

1. Рассмотрим приращение:

$$f_\tau(x + th) - f_\tau(x) = \mathbb{E}_e [f(x + th + \tau e) - f(x + \tau e)].$$

Поделим на t и рассмотрим предел:

$$\lim_{t \rightarrow 0} \frac{f_\tau(x + th) - f_\tau(x)}{t} = \mathbb{E} \left[\lim_{t \rightarrow 0} \frac{f(x + th + \tau e) - f(x + \tau e)}{t} \right] = \langle \mathbb{E} [\nabla f(x + \tau e)], h \rangle.$$

Заметим, что для любого $t \in [-1, 1]$:

$$\mathbb{E}[\nabla f(x + \tau e)] = \mathbb{E}[\nabla f(x + t\tau e)].$$

А в Теореме Л15.2 мы получили, что

$$\mathbb{E}[\nabla f(x + t\tau e)] = \mathbb{E}\left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right].$$

Таким образом получили требуемое.

2. Выпуклость f_τ следует из выпуклости f . Для доказательства второго факта воспользуемся выпуклостью f :

$$f(x) \leq f(x + \tau e) + \langle \nabla f(x), x - (x + \tau e) \rangle = f(x + \tau e) - \tau \langle \nabla f(x), e \rangle.$$

Возьмем математическое ожидание и используем симметрию распределения:

$$f(x) \leq \mathbb{E}[f(x + \tau e)] = f_\tau(x),$$

то есть $f_\tau(x) - f(x) \geq 0$. Для верхней оценки используем M -Липшицевость f :

$$f(x + \tau e) - f(x) \leq M \|\tau e\|_2 = M\tau.$$

Усредняя по e , получим $f_\tau(x) - f(x) \leq \tau G$.

3. Из первого пункта имеем

$$\nabla f_\tau(x) = \mathbb{E}\left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right].$$

Воспользуемся M -Липшицевостью f :

$$\begin{aligned} \|\nabla f_\tau(x)\|_2 &\leq \mathbb{E}\left[d \frac{|f(x + \tau e) - f(x - \tau e)|}{2\tau} \|e\|_2\right] \\ &\leq \mathbb{E}\left[d \frac{M\|(x + \tau e) - (x - \tau e)\|_2}{2\tau}\right] = dM. \end{aligned}$$

■

Утверждение Л15.3 формализует, что сферическое сглаживание делает целевую функцию «хорошей» в аналитическом и алгоритмическом смысле даже тогда, когда исходная f может быть негладкой.

Утверждение Л15.4. Пусть дана M -Липшицева функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Определим оценку градиента

$$g(x, e) = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad e \sim U(S^{d-1}).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливо:

1. $\mathbb{E}_{e \sim U(S^{d-1})}[g(x, e)] = \nabla f_\tau(x)$,
2. $\mathbb{E}_{e \sim U(S^{d-1})}\|g(x, e)\|_2^2 \leq d^2 M^2$.

Доказательство.

1. Следует из первого пункта Утверждения Л15.3.
2. Воспользуемся M -Липшицевостью:

$$\mathbb{E} \left[\|g(x, e)\|_2^2 \right] = \frac{d^2}{4\tau^2} \mathbb{E} \left[|f(x + \tau e) - f(x - \tau e)|^2 \right] \leq d^2 M^2.$$

■

Покажем сходимость Алгоритма Л15.2 для выпуклой негладкой f .

Теорема Л15.3. Пусть задача безусловной оптимизации (Л15.1) с γ -Липшицевой выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л15.2). Тогда при

$$\gamma_k = \gamma \leq \frac{\|x^0 - x^*\|_2}{dM\sqrt{K}}$$

справедлива следующая оценка сходимости:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M.$$

В частности, при выборе

$$\tau \leq \frac{d\|x^0 - x^*\|_2}{\sqrt{K}}$$

имеем

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.$$

Возьмем условное математическое ожидание:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f_\tau(x^k), x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right].$$

Запишем выпуклость f_τ :

$$\langle \nabla f_\tau(x^k), x^k - x^* \rangle \geq f_\tau(x^k) - f_\tau(x^*)$$

и, используя результат Утверждения Л15.4, получим:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma (f_\tau(x^k) - f_\tau(x^*)) + \gamma^2 d^2 M^2.$$

Перейдем к полному математическому ожиданию и раскроем рекурсию:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \|x^0 - x^*\|_2^2 - 2\gamma \sum_{k=0}^{K-1} \mathbb{E} \left[f_\tau(x^k) - f_\tau(x^*) \right] + K\gamma^2 d^2 M^2.$$

Отбросим неотрицательный левый член и поделим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [f_\tau(x^k) - f_\tau(x^*)] \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma d^2 M^2}{2}.$$

Воспользуемся выпуклостью f_τ :

$$\mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma d^2 M^2}{2}.$$

Минимизируя правую часть по γ , получаем, что

$$\gamma = \frac{\|x^0 - x^*\|_2}{dM\sqrt{K}}.$$

Тогда

$$\mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Пользуясь тем, что $0 \leq f_\tau(x) - f(x) \leq \tau M$,

$$\begin{aligned} \mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f(x^*) \right] &\leq \mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] + \tau M \\ &\leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M. \end{aligned}$$

При выборе $\tau \leq \frac{d\|x^0 - x^*\|_2}{\sqrt{K}}$ получаем

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f(x^*) \right] \leq \frac{2dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

■

Л15.2.3 Ключевые работы

Методы оптимизации нулевого порядка для дообучения больших языковых моделей представляют собой активно развивающуюся область исследований. Ниже представлены ключевые работы, которые расширяют и углубляют понимание данного направления.

- MeZO (Memory-efficient Zeroth-Order) представляет собой основополагающую работу в области применения методов нулевого порядка для дообучения LLM. Авторы адаптируют классический ZO-SGD для работы in-place, обеспечивая дообучение моделей с тем же объемом памяти, что и инференс, достигая при этом производительности, сопоставимой с методами первого порядка при снижении потребления памяти до 12 раз.
- LeZO (Layer-wise Zeroth-Order) вводит послонную разреженную вычислительную стратегию для ZO-оптимизации, обрабатывая слои как фундаментальные единицы разреживания. Метод динамически возмущает различные подмножества параметров на каждом шаге, достигая ускорения более чем в 3 раза по сравнению с MeZO на задачах классификации без дополнительных накладных расходов на память.

- ZO-AdaMU предлагает оригинальное решение проблем осцилляций и вычислительных издержек в MeZO путем адаптации возмущений с моментумом в стохастической аппроксимации градиента. В отличие от существующих адаптивных методов моментума, алгоритм перемещает моментум на симулируемое возмущение в стохастической аппроксимации градиента, что теоретически и эмпирически доказано как более эффективный способ улучшения стабильности и скорости сходимости в ZO-SGD для дообучения LLM.
- HiZOO (Hessian-informed Zeroth-Order Optimizer) впервые интегрирует информацию о диагональном гессиане в оптимизацию нулевого порядка для дообучения LLM. Данный подход решает проблему гетерогенных кривизн в различных размерностях параметров, обеспечивая существенное ускорение сходимости при сохранении преимуществ в потреблении памяти.
- LOZO (Low-rank Zeroth-Order) предлагает новый подход к оценке градиентов нулевого порядка через использование низкоранговых структур. Метод эффективно захватывает низкоранговую структуру градиентов, характерную для дообучения LLM, что позволяет значительно улучшить сходимость по сравнению с существующими ZO-методами, приближаясь к производительности алгоритмов первого порядка.
- MeZO-SVRG интегрирует техники редукции дисперсии в ZO-оптимизацию для повышения стабильности и скорости сходимости при дообучении на основе инференса. Метод превосходит MeZO на 20% по точности тестирования при двукратном снижении времени GPU-часов, существенно уменьшая требования к памяти по сравнению с стохастическим градиентным спуском первого порядка.
- JAGUAR SignSGD / Muon представляют первые методы ZO-оптимизации с гарантиями сходимости для алгоритмов SignSGD и Muon в стохастическом невыпуклом случае. Подходы используют JAGUAR-аппроксимацию градиента и координатный моментум, требуя лишь $\mathcal{O}(1)$ вычислений оракула за итерацию и демонстрируя конкурентную производительность с методами первого порядка при значительной экономии памяти.

Список литературы

- [1] Necdet Serhat Aybat, Alireza Fallah, Mert Gurbuzbalaban, and Asuman Ozdaglar. A universally optimal multistage accelerated stochastic gradient method, 2019.
- [2] Francis Bach and Eric Moulines. Non-asymptotic analysis of stochastic approximation algorithms for machine learning. In *Advances in Neural Information Processing Systems*, volume 24, pages 451–459, December 2011.
- [3] Aleksandr Beznosikov, Valentin Samokhin, and Alexander Gasnikov. Distributed saddle point problems: lower bounds, near-optimal and robust algorithms*. *Optimization Methods and Software*, page 1–18, March 2025.
- [4] Christopher M. Bishop. *Neural Networks for Pattern Recognition*. Oxford University Press, 1995.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Springer, 1 edition, 2007.
- [6] Stephen Boyd and Lieven Vandenbergh. *Convex Optimization*. Cambridge University Press, Cambridge, 2004.